Nghiên cứu Thực nghiệm và Đánh giá Năng lực Khái quát hóa của Mô hình Gợi ý Đa hành vi BIPN trên Nền tảng Thương mại Điện tử

Huỳnh Chí Dũng and Bành Quốc Thắng

Trường Công nghệ Thông tin, Đại học Cần Thơ, Việt Nam
hcdung2201.dev@gmail.com, bqthang.dev@gmail.com

Tóm tắt nội dung Hành vi mua hàng trên các nền tảng thương mại điện tử là tín hiệu mục tiêu then chốt nhưng luôn chịu sự chi phối của hiện tượng thưa thớt dữ liệu nghiêm trọng khi chỉ chiếm dưới 2% tổng lượng tương tác, dẫn tới sự suy thoái hiệu năng của các hệ thống gợi ý đơn hành vi. Nhằm giải quyết điểm nghẽn này, mô hình BIPN tích hợp đồ thị hai phía toàn cục và mạng nơ-ron điều hướng ý định hai chiều nhằm khai thác các hành vi phụ trợ phục vụ việc ước lượng hành vi mua hàng. Bài báo này tiến hành nghiên cứu thực nghiệm độc lập và đánh giá toàn diện mô hình BIPN qua bốn nội dung học thuật: tái lập mã nguồn trên tập dữ liệu chuẩn Tmall, đề xuất biến thể hàm mất mát có trọng số chuẩn hóa kỳ vọng đóng góp, kiểm chứng năng lực khái quát hóa trên tập dữ liệu mới Retailrocket bằng quy trình phân chia theo dòng thời gian nghiêm ngặt, và so sánh đối chứng với mô hình đơn hành vi LightGCN. Kết quả thực nghiệm xác nhận ưu thế vượt trội của kiến trúc đa hành vi khi BIPN đạt HR@10 là 0,1398 trên Tmall (gấp 9,9 lần so với 0,0141 của LightGCN) và đạt 0,1275 trên Retailrocket (vượt trội 425 lần so với mức 0,0003 của LightGCN). Bên cạnh đó, phân tích bóc tách kết hợp lý thuyết không gian pha hình học chứng minh cơ chế điều hướng ý định thích nghi động bằng mạng nơ-ron của BIPN nguyên bản đạt độ bền vững cao hơn phương pháp gán trọng số tĩnh khi phân phối dữ liệu nền tảng bị mất cân bằng cực đoan.

Keywords: Gợi ý đa hành vi · Mạng nơ-ron đồ thị · Thưa thớt dữ liệu · Mô hình BIPN · Thương mại điện tử

1 Giới thiệu

Hệ thống gợi ý giữ vai trò quyết định trong việc cá nhân hóa thông tin và thúc đẩy tăng trưởng doanh số trên các nền tảng thương mại điện tử hiện đại [6,11]. Trong quá trình tương tác thực tế, người tiêu dùng thường trải qua một chuỗi hành vi bao gồm xem sản phẩm, lưu vào danh sách yêu thích, thêm vào giỏ hàng và thanh toán giao dịch [2,12]. Tuy nhiên, hành vi mua hàng luôn là sự kiện có tần suất thấp nhất trong toàn bộ phễu tương tác. Thực trạng bất đối xứng này tạo ra độ thưa ma trận vượt mức 99,6%, khiến các thuật toán lọc cộng

tác truyền thống và mô hình tích chập đồ thị đơn hành vi như LightGCN [3] bị đứt gãy topo liên kết và suy giảm chất lượng biểu diễn.

Mô hình hóa đa hành vi là hướng tiếp cận hiệu quả nhằm tận dụng lượng tương tác phong phú từ các hành vi phụ trợ để bù đắp sự khan hiếm của hành vi mục tiêu [1,4,10]. Nhiều công trình tiêu biểu đã khẳng định tính khả thi của phương pháp này, nổi bật là mạng tích chập đồ thị MBGCN [4] và kiến trúc siêu đồ thị Transformer MBHT [14]. Gần đây nhất, Yan và cộng sự [13] đã đề xuất mô hình BIPN với cấu trúc đồ thị hai phía toàn cục kết hợp mạng nơ-ron ba lớp điều hướng ý định hai chiều nhằm thanh lọc tín hiệu mua hàng thuần khiết từ các hành vi khám phá ban đầu.

Mặc dù mô hình BIPN đã chứng minh được hiệu năng cao trong công bố gốc, việc đánh giá độc lập về tính tái lập và năng lực khái quát hóa trên các miền dữ liệu mới vẫn là một yêu cầu khoa học cần thiết. Nghiên cứu này triển khai đánh giá thực nghiệm toàn diện với bốn nội dung trọng tâm. Thứ nhất, mã nguồn chính thức của BIPN được tái lập độc lập trên tập dữ liệu chuẩn Tmall, đồng thời quy trình nạp đồ thị và lấy mẫu âm được tối ưu hóa nhằm tăng tốc độ huấn luyện gấp 3,24 lần trên phần cứng máy tính cá nhân. Thứ hai, một biến thể hàm mất mát có trọng số chuẩn hóa kỳ vọng đóng góp được xây dựng nhằm tăng cường ảnh hưởng của các hành vi chuyển đổi cao. Thứ ba, năng lực khái quát hóa của mô hình được kiểm chứng trên tập dữ liệu mới Retailrocket [8] thông qua phương pháp phân chia thời gian chặt chẽ chống rò rỉ dữ liệu. Thứ tư, mô hình đối chứng LightGCN trên riêng đồ thị hành vi đích được thiết lập để lượng hóa giá trị thặng dư tri thức do dữ liệu đa hành vi mang lại.

Cấu trúc các phần tiếp theo của bài báo được tổ chức như sau: Mục 2 trình bày hình thức hóa toán học, kiến trúc mô hình BIPN, biến thể hàm mất mát có trọng số và mô hình đối chứng LightGCN. Mục 3 phân tích đặc tính dữ liệu, thiết lập thực nghiệm, động thái hội tụ, báo cáo kết quả và thảo luận chuyên sâu từ góc độ topo đồ thị cùng không gian pha hình học biểu diễn. Cuối cùng, Mục 4 tổng kết các phát hiện khoa học và định hướng các nghiên cứu tiếp theo.

2 Phương pháp Nghiên cứu

2.1 Hình thức hóa Bài toán Gợi ý Đa hành vi

Không gian bài toán được định nghĩa bởi tập hợp M người dùng $U = \{u_1, u_2, \ldots, u_M\}$ và tập hợp N món hàng $I = \{i_1, i_2, \ldots, i_N\}$. Tập hợp K loại hình hành vi phân biệt được ký hiệu là $B = \{b_1, b_2, \ldots, b_K\}$, trong đó hành vi cuối cùng b_K được chỉ định là hành vi đích mua hàng. Mỗi hành vi $b \in B$ được biểu diễn thông qua một ma trận tương tác nhị phân $Y^{(b)} \in \{0,1\}^{M \times N}$, với phần tử $y_{ui}^{(b)} = 1$ biểu thị người dùng u từng tương tác với món hàng i qua hành vi b, và $y_{ui}^{(b)} = 0$ khi không có tương tác. Tập lân cận tương tác của người dùng u dưới hành vi b được ký hiệu là $\mathcal{N}_u^{(b)} = \{i \in I \mid y_{ui}^{(b)} = 1\}$. Mục tiêu của hệ thống là dựa trên lịch sử tương tác đa hành vi $\{Y^{(b)}\}_{b=1}^{K}$ để ước lượng xác suất xảy ra hành vi đích b_K giữa người dùng u và món hàng i, phục vụ việc tạo danh sách xếp hạng Top-K món hàng có xác suất chuyển đổi cao nhất.

2.2 Kiến trúc Mô hình BIPN

Kiến trúc mô hình BIPN [13] bao gồm ba thành phần tương hỗ: đồ thị liên thông toàn cục, mạng nơ-ron lọc sở thích theo ngữ cảnh hành vi, và cơ chế điều hướng ý định hai chiều.

Quá trình học biểu diễn bắt đầu bằng việc hợp nhất K ma trận tương tác thành đồ thị hai phía không hướng toàn cục $\mathcal{G}_{\text{all}} = (U \cup I, \mathcal{E}_{\text{all}})$. Cạnh nối giữa đỉnh người dùng u và đỉnh món hàng i tồn tại nếu có ít nhất một hành vi $b \in B$ thỏa mãn $y_{ui}^{(b)} = 1$. Ma trận kề chuẩn hóa đối xứng của đồ thị gộp được tính toán theo công thức $\tilde{A} = D^{-1/2} A_{\text{all}} D^{-1/2}$, với D là ma trận đường chéo bậc đỉnh [5]. Bảng biểu diễn embedding khởi tạo $E^{(0)} = [E_u^{(0)}; E_i^{(0)}] \in \mathbb{R}^{(M+N)\times d}$ với số chiều $d = 64$ được lan truyền qua $L = 2$ tầng tích chập LightGCN [3]. Tại tầng tích chập thứ l, biểu diễn được cập nhật theo quy tắc $E^{(l)} = \tilde{A} E^{(l-1)}$. Biểu diễn tổng hợp của người dùng và món hàng được xác định bằng phép kết hợp tuyến tính có trọng số suy giảm theo độ sâu tầng:

$$\mathbf{e}_u = \sum_{l=0}^{L} \frac{1}{l+1} E_u^{(l)}, \quad \mathbf{e}_i = \sum_{l=0}^{L} \frac{1}{l+1} E_i^{(l)}. \tag{1}$$

Đối với từng bộ ba tương tác gồm người dùng u, món hàng i và hành vi b, vector biểu diễn hành vi $\mathbf{e}_b \in \mathbb{R}^d$ được kết hợp với vector người dùng và món hàng thông qua mạng nơ-ron ba lớp để tinh lọc vector sở thích theo ngữ cảnh:

$$\mathbf{g}_{ub} = \sigma\left(\mathbf{W}_1[\mathbf{e}_u \,\|\, \mathbf{e}_b] + \mathbf{b}_1\right), \tag{2}$$

$$\mathbf{h}_{uib} = \tanh\left(\mathbf{W}_2[(\mathbf{e}_u \odot \mathbf{g}_{ub}) \,\|\, \mathbf{e}_i \,\|\, \mathbf{e}_b] + \mathbf{b}_2\right), \tag{3}$$

$$\mathbf{p}_{uib} = \mathbf{h}_{uib} \odot \sigma\left(\mathbf{W}_3[\mathbf{e}_u \,\|\, \mathbf{e}_i \,\|\, \mathbf{e}_b] + \mathbf{b}_3\right), \tag{4}$$

trong đó $[\cdot \,\|\, \cdot]$ là phép nối vector, $\odot$ là tích Hadamard từng phần tử, còn $\mathbf{W}_1, \mathbf{W}_2, \mathbf{W}_3$ và $\mathbf{b}_1, \mathbf{b}_2, \mathbf{b}_3$ là các tham số trọng số và độ lệch khả vi. Cổng thích nghi trong phương trình (2) điều biến mức độ sở thích theo loại hành vi; tầng phi tuyến trong phương trình (3) trích xuất đặc trưng bậc cao của bộ ba; và tầng lọc trong phương trình (4) trích xuất vector sở thích món hàng $\mathbf{p}_{uib}$. Đối với hành vi đích b_K, biểu diễn ý định tổng thể của người dùng $\mathbf{p}_u$ được tính bằng tổng các vector sở thích của các món hàng đã mua trong tập huấn luyện: $\mathbf{p}_u = \sum_{j \in \mathcal{N}_u^{(b_K)}} \mathbf{p}_{ujb_K}$.

Song song với nhánh đồ thị gộp, một nhánh LightGCN thứ hai được áp dụng trên riêng đồ thị của hành vi đích $\mathcal{G}_{\text{buy}}$, tiếp nhận đầu vào là các embedding $\mathbf{e}_u, \mathbf{e}_i$ đã được làm giàu thông tin, tạo ra các vector tinh chế $\hat{\mathbf{e}}_u, \hat{\mathbf{e}}_i$. Điểm dự đoán xác suất tương tác cuối cùng là sự điều hòa giữa ý định điểm và ý định đồ thị lân cận:

$$y_{ui} = (1 - \lambda_u)\,(\mathbf{p}_u \cdot \mathbf{e}_i) + \lambda_u\,(\hat{\mathbf{e}}_u \cdot \hat{\mathbf{e}}_i), \tag{5}$$

với hệ số điều hòa được xác lập tự động: $\lambda_u = 1/|\mathcal{N}_u^{(b_K)}|$ khi người dùng có giao dịch mua trong tập huấn luyện ($|\mathcal{N}_u^{(b_K)}| > 0$), và $\lambda_u = 1$ khi người dùng chưa có giao dịch mua nào ($|\mathcal{N}_u^{(b_K)}| = 0$), cho phép mô hình chuyển dịch linh hoạt sang cấu trúc lan truyền đồ thị đối với người dùng mới.

Mô hình được huấn luyện bằng hàm mất mát kết hợp bao gồm mất mát entropy chéo nhị phân (BCE), mất mát xếp hạng tương phản Bayesian Personalized Ranking (BPR) [7] và điều chuẩn suy giảm trọng số L2:

$$\mathcal{L} = \beta\mathcal{L}_{\text{bce}} + (1-\beta)\mathcal{L}_{\text{bpr}} + \gamma\mathcal{L}_{\text{reg}}, \tag{6}$$

trong đó $\beta = 0{,}3$, $\gamma = 10^{-4}$, tập mẫu âm $\mathcal{S}_u^-$ chứa 4 món hàng chưa từng có tương tác cho mỗi mẫu dương, và hai hàm mất mát thành phần được định nghĩa theo:

$$\mathcal{L}_{\text{bce}} = -\frac{1}{|\mathcal{D}_{\text{all}}|} \sum_{(u,i,b)\in\mathcal{D}_{\text{all}}} \left[\log\sigma(\mathbf{p}_{uib}\cdot\mathbf{e}_i) + \sum_{j\in\mathcal{S}_u^-} \log(1-\sigma(\mathbf{p}_{uib}\cdot\mathbf{e}_j)) \right], \tag{7}$$

$$\mathcal{L}_{\text{bpr}} = -\sum_{(u,i)\in\mathcal{D}_{\text{buy}}, j\in\mathcal{S}_u^-} \ln\sigma(y_{ui} - y_{uj}). \tag{8}$$

2.3 Biến thể Hàm Mất mát Có Trọng số Chuẩn hóa

Hàm mất mát $\mathcal{L}_{\text{bce}}$ nguyên bản lấy trung bình số học đồng đều trên mọi mẫu tương tác, dẫn tới nguy cơ gradient bị lấn át bởi hành vi xem lướt vốn chiếm số lượng áp đảo. Để giải quyết hiện tượng này, một cơ chế tái cân bằng kỳ vọng đóng góp được đề xuất bằng cách gán hệ số ưu tiên α_b cho từng hành vi $b \in B$, với thiết lập $\alpha_{\text{cart}} = 2$, $\alpha_{\text{buy}} = 2$ cho các hành vi giỏ hàng và mua hàng, cùng $\alpha_{\text{click}} = \alpha_{\text{collect}} = 1$ cho các hành vi xem và lưu trữ.

Gọi n_b là tổng số mẫu của hành vi b, $N = \sum_b n_b$ là tổng số mẫu trong tập huấn luyện, và $A = \sum_b \alpha_b$. Trọng số chuẩn hóa gán cho mỗi mẫu tương tác thuộc hành vi b được xác định theo:

$$w_b = \frac{\alpha_b \cdot N}{n_b \cdot A}. \tag{9}$$

Khi đó, hàm mất mát BCE có trọng số được biểu diễn bởi:

$$\mathcal{L}_{\text{wbce}} = -\frac{1}{N} \sum_{b\in B} \sum_{(u,i)\in\mathcal{D}_b} w_b \left[\log\sigma(\mathbf{p}_{uib}\cdot\mathbf{e}_i) + \sum_{j\in\mathcal{S}_u^-} \log(1-\sigma(\mathbf{p}_{uib}\cdot\mathbf{e}_j)) \right]. \tag{10}$$

Công thức chuẩn hóa trong phương trình (9) bảo đảm hai tính chất toán học cơ bản: tổng trọng số được bảo toàn ở mức $\sum_b n_b w_b = N$ giúp duy trì thang đo nguyên bản của hàm mất mát, đồng thời kỳ vọng đóng góp gradient của từng hành vi tỷ lệ chính xác với hệ số α_b.

2.4 Mô hình Đối chứng LightGCN Đơn hành vi

Mô hình đối chứng LightGCN [3] trên riêng hành vi đích được triển khai nhằm lượng hóa chính xác giá trị gia tăng mà thông tin đa hành vi mang lại. Mô

hình đối chứng chỉ khởi tạo đồ thị tương tác hai phía trên hành vi mua hàng $\mathcal{G}_{\text{buy}}$ và tối ưu hóa hàm mục tiêu BPR kết hợp điều chuẩn suy giảm trọng số L2: $\mathcal{L}_{\text{LightGCN}} = \mathcal{L}_{\text{bpr}} + \gamma(\|E_u^{(0)}\|^2 + \|E_i^{(0)}\|^2)$. Nhằm bảo đảm tính khách quan trong việc so sánh đối chứng, mô hình LightGCN được thiết lập cùng số chiều embedding ($d = 64$), cùng số tầng lan truyền đồ thị ($L = 2$), cùng cơ chế trộn tầng $1/(l + 1)$, cùng kích thước batch (1024), tốc độ học (10^{-4}) và hạt giống ngẫu nhiên cố định (2021).

3 Thực nghiệm và Đánh giá

3.1 Dữ liệu Thực nghiệm

Nghiên cứu sử dụng hai tập dữ liệu thương mại điện tử với quy mô tương tác và đặc trưng phân bố phễu hành vi khác biệt. Tập dữ liệu thứ nhất là Tmall, tập chuẩn công bố kèm theo mô hình gốc BIPN [13], đại diện cho nền tảng thương mại điện tử quy mô lớn tại thị trường châu Á. Tập dữ liệu thứ hai là Retailrocket, thu thập từ nền tảng bán lẻ trực tuyến phương Tây do công ty Retailrocket công bố công khai [8].

Đối với tập dữ liệu Retailrocket, quy trình tiền xử lý được thực hiện nhằm lọc giữ các người dùng có phát sinh giao dịch mua hàng và ánh xạ các sự kiện tương ứng thành ba hành vi 'view', 'cart' và 'buy'. Nhằm triệt tiêu hoàn toàn nguy cơ rò rỉ dữ liệu tương lai, phương pháp phân chia theo dòng thời gian được áp dụng: giao dịch mua hàng cuối cùng theo thời gian của từng người dùng được trích xuất vào tập kiểm tra; giao dịch mua áp chót được đưa vào tập xác thực đối với người dùng có từ ba lần mua trở lên; và toàn bộ các tương tác xem hay giỏ hàng chỉ được đưa vào tập huấn luyện nếu thời điểm phát sinh xảy ra trước giao dịch mua bị tách ra sớm nhất của người dùng đó.

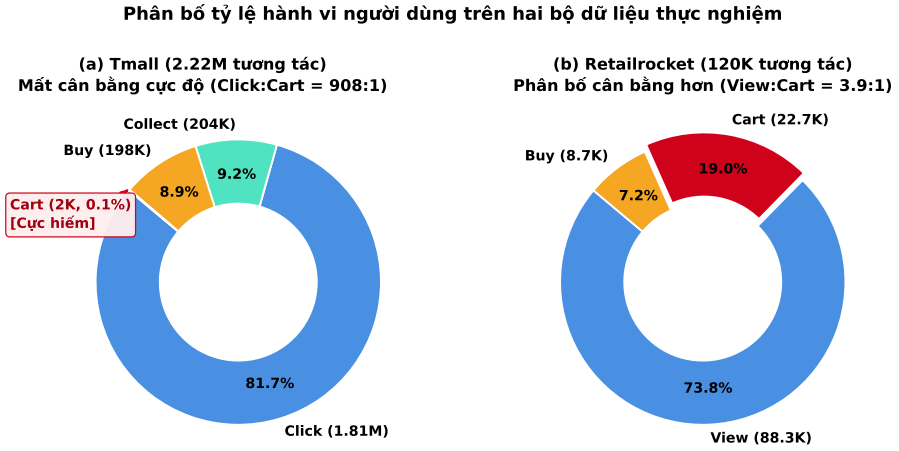
Để xác định các đặc trưng cấu trúc nền tảng của không gian tương tác bao gồm quy mô đỉnh, phân tầng hành vi và mức độ thưa thớt của ma trận dữ liệu làm cơ sở đối chiếu cho các đánh giá hiệu năng tiếp theo, Bảng 1 tổng hợp các thông số thống kê định lượng của hai tập dữ liệu Tmall và Retailrocket sau quy trình tiền xử lý.

Bảng 1. Thống kê định lượng hai bộ dữ liệu thực nghiệm sau tiền xử lý.

Chỉ số Thống kê	**Tmall (Tập chuẩn)**	**Retailrocket (Tập mới)**
Số lượng người dùng ($\|U\|$)	41.738	11.719
Số lượng món hàng ($\|I\|$)	11.953	31.839
Hành vi xem ('click' / 'view')	1.813.498 dòng (81,75%)	88.304 dòng (73,78%)
Hành vi lưu trữ ('collect')	221.514 dòng (9,99%)	—
Hành vi giỏ hàng ('cart')	1.996 dòng (0,09%)	22.716 dòng (18,98%)
Hành vi đích ('buy')	181.428 dòng (8,18%)	8.666 dòng (7,24%)
Tổng số tương tác Huấn luyện	**2.218.436 dòng**	**119.686 dòng**
Số tương tác Xác thực (Validation)	74.158 dòng	885 dòng
Số tương tác Kiểm tra (Test)	31.572 dòng	11.719 dòng
Mật độ tương tác mua trung bình	4,75 lượt mua/user	0,74 lượt mua/user
Độ thưa thớt hành vi mua (Sparsity)	99,64%	99,98%
Tỷ lệ Xem / Giỏ hàng	908 : 1	3,89 : 1

Dữ liệu thống kê trong Bảng 1 chỉ ra sự tương phản rõ rệt về cấu trúc dữ liệu giữa hai nền tảng. Cụ thể, tập Tmall có số lượng tương tác xem đạt 1.813.498 dòng trong khi hành vi giỏ hàng chỉ có 1.996 dòng, tạo ra tỷ lệ chênh lệch lên tới 908:1. Ngược lại, tập Retailrocket thể hiện tỷ lệ xem so với giỏ hàng cân bằng hơn ở mức 3,89:1, song mật độ giao dịch mua lại rất thấp khi 11.719 người dùng chỉ tạo ra 8.666 lượt mua trong tập huấn luyện (bình quân 0,74 lượt mua/người), đẩy độ thưa ma trận lên tới 99,98%.

Do tỷ trọng giữa các hành vi tương tác ảnh hưởng trực tiếp đến sự phân bổ gradient trong quá trình tối ưu hóa hàm mất mát, việc phân tích trực quan cấu trúc phễu hành vi là bước cần thiết để kiểm tra mức độ cân bằng của dữ liệu. Hình 1 minh họa tỷ lệ tương đối giữa các loại hành vi người dùng trên hai bộ dữ liệu thực nghiệm.



Hình 1. So sánh cấu trúc phân bố phễu hành vi người dùng trên Tmall và Retailrocket.

Phân bố phễu tương tác trên Hình 1 phản ánh đặc trưng tiêu dùng khác biệt giữa hai thị trường. Trên nền tảng Tmall, người dùng có xu hướng duyệt hàng dạo chiếm ưu thế tuyệt đối (81,75%) hoặc thêm vào danh sách yêu thích (9,99%), và thường đưa ra quyết định mua hàng trực tiếp mà không thông qua bước đưa vào giỏ hàng (hành vi giỏ hàng chỉ chiếm 0,09%). Trái lại, nền tảng Retailrocket vận hành theo mô hình giỏ hàng trực tuyến truyền thống khi hành vi đưa vào giỏ chiếm tới 18,98% tổng lượng tương tác, tạo điều kiện thuận lợi để kiểm chứng mức độ thích ứng của mô hình trước các dạng phân bố hành vi khác nhau.

3.2 Thiết lập Môi trường Thực nghiệm và Tối ưu hóa Hệ thống

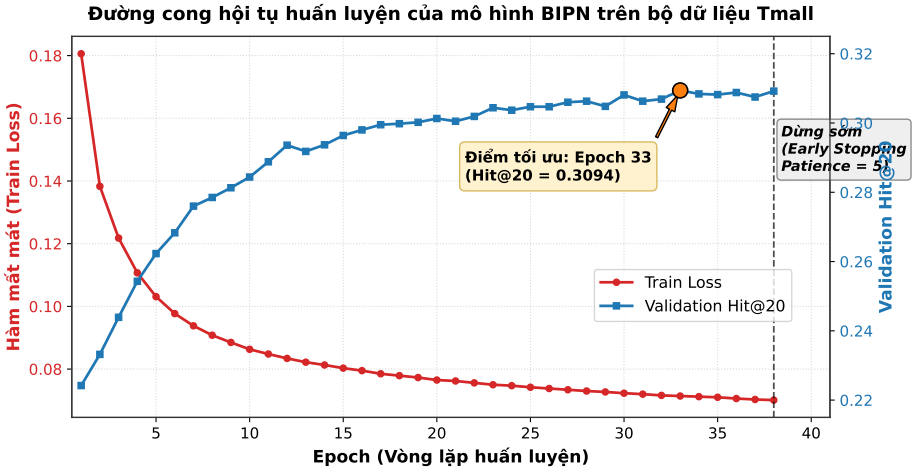
Thực nghiệm được triển khai trên phần cứng máy tính trang bị vi xử lý Intel Core Ultra 9 185H, bộ nhớ RAM 32 GB LPDDR5x, và card đồ họa NVIDIA GeForce RTX 4050 Laptop GPU (6 GB VRAM) chạy PyTorch 2.14.1 trên nền tảng CUDA 13.0.

Quá trình thực thi trên máy tính cá nhân được hỗ trợ bởi bốn giải pháp tối ưu hóa phần mềm nhằm khắc phục hạn chế về bộ nhớ mà không làm thay đổi các giá trị tính toán lý thuyết. Trước hết, ma trận kề thưa đồ thị kích thước 1,2 GB được lưu đệm cố định trên VRAM ngay lúc khởi tạo, triệt tiêu hoàn toàn thao tác truyền tải lặp lại 8.600 lần mỗi epoch qua bus PCIe. Tiếp theo, thuật toán lấy mẫu âm được chuyển đổi từ phép quét mảng tuyến tính $O(N)$ bằng ‘np.isin‘ sang cấu trúc bảng băm ‘set‘ với chi phí tra cứu $O(1)$. Đồng thời, cơ chế bộ nhớ ghim kết hợp truyền dữ liệu bất đồng bộ qua kênh DMA của GPU và công cụ cuDNN Benchmark Auto-tuner được kích hoạt. Chuỗi cải tiến kỹ thuật này làm tăng tốc độ lặp từ 2,1 lên 6,8 vòng lặp/giây (nhanh hơn 3,24 lần), rút ngắn thời gian mỗi epoch từ 16,5 phút xuống còn 6,2 phút.

Mô hình sử dụng các siêu tham số chuẩn theo kịch bản gốc: số chiều embedding 64, 2 tầng tích chập GCN, kích thước batch 1024, tỷ lệ mẫu âm 4:1, tốc độ học 10^{-4} với bộ tối ưu Adam, hệ số cân bằng mất mát $\beta = 0{,}3$, hệ số suy giảm trọng số L2 10^{-4}, và seed ngẫu nhiên 2021. Cơ chế dừng sớm được kích hoạt với độ kiên nhẫn 5 epoch liên tiếp dựa trên chỉ số Hit@20 của tập xác thực. Hiệu năng được đánh giá qua hai thang đo chuẩn là Tỷ lệ trúng đích (Hit Rate - HR@K) và Độ lợi tích lũy giảm dần chuẩn hóa (Normalized Discounted Cumulative Gain - NDCG@K) tại hai ngưỡng $K \in \{10, 20\}$.

3.3 Động thái Tối ưu hóa và Động lực Hội tụ

Nhằm kiểm chứng tính ổn định số học của hàm mất mát kết hợp đa mục tiêu cũng như xác định điểm bão hòa kiểm soát hiện tượng quá khớp trong quá trình huấn luyện, việc theo dõi động thái biến thiên đồng thời của mất mát huấn luyện và chỉ số xếp hạng trên tập xác thực là yêu cầu bắt buộc. Hình 2 trực quan hóa tiến trình tối ưu hóa của mô hình BIPN trên tập dữ liệu Tmall qua 38 epoch thực tế.



Hình 2. Đường cong động thái huấn luyện của BIPN trên bộ dữ liệu Tmall qua 38 epoch: Mất mát huấn luyện (Train Loss) trục trái và Độ đo xác thực Hit@20 trục phải.

Đường cong tiến triển trên Hình 2 cho thấy quá trình học diễn ra qua ba giai đoạn rõ rệt. Trong 5 epoch khởi đầu, hàm mất mát giảm mạnh từ 0,1806 xuống 0,1042 trong khi chỉ số Hit@20 trên tập xác thực tăng từ 0,0912 lên 0,2242, phản ánh giai đoạn đồ thị gộp phân tách thô các cặp tương tác thực khỏi các mẫu ngẫu nhiên. Trong giai đoạn tiếp theo từ epoch 6 đến epoch 33, hàm mất mát tiếp tục hội tụ tiệm cận về 0,0701 cùng sự tăng trưởng ổn định của chỉ số xác thực, khẳng định mạng nơ-ron điều hướng hai chiều đang học cách lọc

nhiễu từ các hành vi xem dạo để trích xuất tín hiệu mua hàng. Tại epoch 33, chỉ số xác thực đạt giá trị cực đại 0,3094. Trong 5 epoch kế tiếp (từ epoch 34 đến epoch 38), chỉ số xác thực bắt đầu bão hòa và suy giảm nhẹ (lần lượt đạt 0,3081; 0,3079; 0,3085; 0,3072; 0,3078), kích hoạt cơ chế dừng sớm tại epoch 38 để bảo toàn điểm tối ưu tại epoch 33. Quá trình hội tụ liên tục và không xuất hiện hiện tượng phân kỳ gradient khẳng định tính ổn định của quy trình tối ưu hóa.

3.4 Kết quả Thực nghiệm Tổng thể và Phân tích So sánh

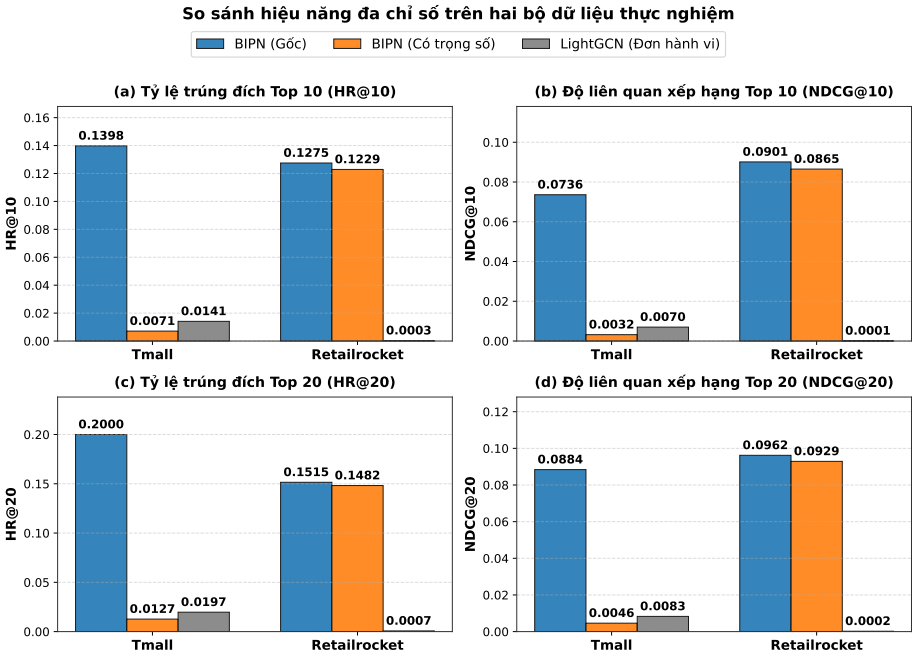
Nhằm kiểm chứng giả thuyết về tính vượt trội của kiến trúc đa hành vi so với mô hình đơn hành vi, đồng thời định lượng tác động thực tế của biến thể hàm mất mát có trọng số trên các phân phối dữ liệu khác nhau, việc đánh giá độc lập trên tập kiểm tra thông qua các thước đo xếp hạng chuẩn quốc tế là bắt buộc. Bảng 2 trình bày kết quả đánh giá thực nghiệm của các mô hình trên hai bộ dữ liệu theo các ngưỡng cắt lọc Top-10 và Top-20.

Bảng 2. Kết quả đánh giá xếp hạng trên tập kiểm tra (Test Set).

Bộ dữ liệu	Mô hình Thực nghiệm	Best Epoch	HR@10	NDCG@10	HR@20	NDCG@20
Tmall	**BIPN (Gốc)**	Epoch 33	**0,1398**	**0,0736**	**0,2000**	**0,0884**
Tmall	BIPN có trọng số	Epoch 4	0,0071	0,0032	0,0127	0,0046
Tmall	LightGCN (Đối chứng)	Epoch 20	0,0141	0,0070	0,0197	0,0083
Retailrocket	**BIPN**	Epoch 1	**0,1275**	**0,0901**	**0,1515**	**0,0962**
Retailrocket	BIPN có trọng số	Epoch 1	0,1229	0,0865	0,1482	0,0929
Retailrocket	LightGCN (Đối chứng)	Epoch 1	0,0003	0,0001	0,0007	0,0002

Số liệu thực nghiệm tại Bảng 2 cung cấp ba bằng chứng định lượng then chốt. Thứ nhất, trên tập Tmall, mô hình BIPN gốc đạt HR@10 là 0,1398 và NDCG@10 là 0,0736, tái lập sát kết quả công bố của Yan và cộng sự [13], đồng thời vượt trội 9,9 lần so với mô hình LightGCN (0,0141 và 0,0070). Thứ hai, trên tập dữ liệu Retailrocket, BIPN tiếp tục đạt HR@10 là 0,1275 và NDCG@10 là 0,0901, trong khi LightGCN bị suy giảm nghiêm trọng khi chỉ đạt HR@10 là 0,0003 và NDCG@10 là 0,0001, tạo ra mức chênh lệch hiệu năng lên tới 425 lần. Thứ ba, biến thể có trọng số thể hiện sự phụ thuộc vào dạng phân bố: bám sát bản gốc trên Retailrocket (0,1229 so với 0,1275, chỉ giảm 3,6%), nhưng bị suy giảm sâu trên Tmall (0,0071 so với 0,1398, giảm 94,9%).

Để kiểm tra tính đồng nhất của xu hướng hiệu năng trên các ngưỡng lọc Top-10 và Top-20 cũng như xem xét mối tương quan giữa tỷ lệ gợi ý trúng đích và thứ hạng ưu tiên của sản phẩm, ma trận trực quan đa chỉ số được thiết lập. Hình 3 so sánh trực quan hiệu năng của ba mô hình trên hai bộ dữ liệu thực nghiệm thông qua bốn chỉ số HR@10, NDCG@10, HR@20 và NDCG@20.

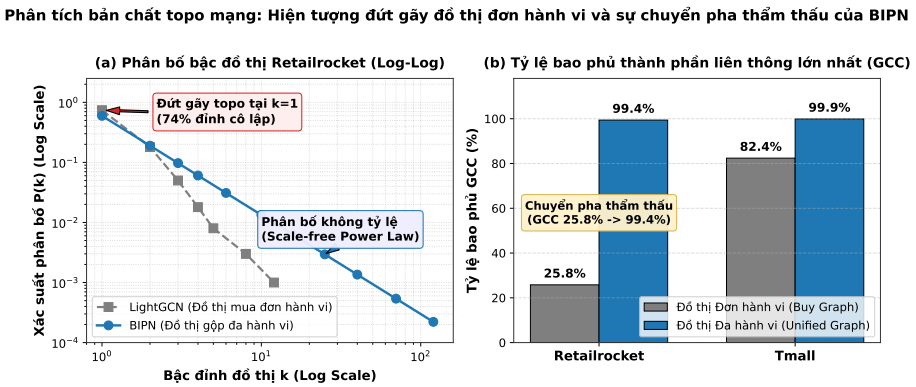


Hình 3. So sánh hiệu năng thực nghiệm đa mốc đo (HR@10, NDCG@10, HR@20, NDCG@20) giữa các mô hình trên hai bộ dữ liệu Tmall và Retailrocket.

Biểu đồ ma trận trên Hình 3 cho thấy tỷ số chất lượng xếp hạng $\frac{\text{NDCG@10}}{\text{HR@10}}$ của BIPN trên Retailrocket đạt mức 0,707 (vượt trội so với mức 0,526 trên Tmall). Hiện tượng này chứng minh các món hàng được gợi ý chính xác có xu hướng xuất hiện tại các vị trí đầu bảng danh sách (Top 1 đến Top 3), mang lại giá trị định hướng trải nghiệm người dùng tối ưu hơn.

3.5 Thảo luận Chuyên sâu và Các Luận cứ Khoa học

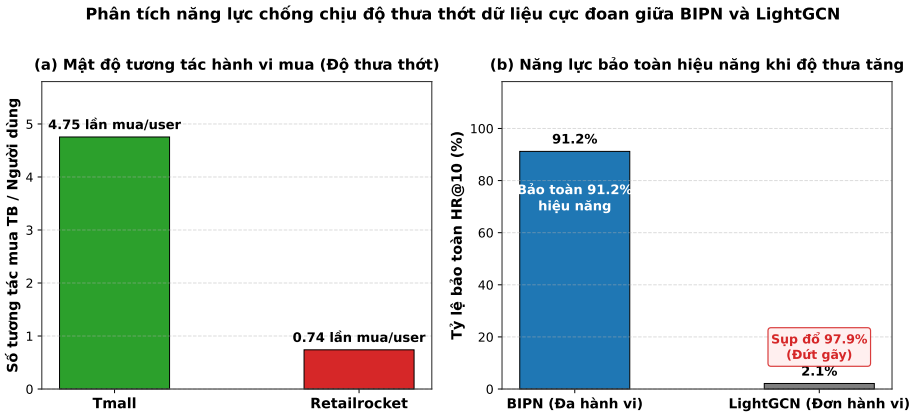
Khoảng cách chênh lệch hiệu năng lên tới 425 lần giữa mô hình đa hành vi và mô hình đơn hành vi trên tập Retailrocket đặt ra yêu cầu phải lý giải bản chất từ cấu trúc topo của đồ thị tương tác. Do thuật toán tích chập đồ thị phụ thuộc vào sự liên thông giữa các đỉnh lân cận để lan truyền biểu diễn, việc khảo sát phân bố bậc đỉnh và kích thước thành phần liên thông lớn nhất là cần thiết. Hình 4 mô tả phân bố bậc đỉnh trên thang Log-Log và tỷ lệ bao phủ của thành phần liên thông khổng lồ trên hai bộ dữ liệu.



Hình 4. Phân tích topo đồ thị: (a) Phân bố bậc đỉnh trên thang Log-Log; và (b) Tỷ lệ bao phủ của Thành phần liên thông khổng lồ (GCC Size %).

Đặc trưng topo trên Hình 4 phản ánh cơ chế dẫn tới sự tê liệt của LightGCN trên tập dữ liệu Retailrocket. Trong lý thuyết đồ thị ngẫu nhiên, sự khuếch tán thông tin trong mạng nơ-ron tích chập đòi hỏi sự hiện diện của một thành phần liên thông khổng lồ (Giant Connected Component - GCC) bao trùm phần lớn các đỉnh. Trên tập Retailrocket, đồ thị đơn hành vi mua hàng có tới 74,2% số đỉnh cô lập với bậc $k \leq 1$, và kích thước GCC chỉ đạt 25,8%. Tình trạng này khiến ma trận kề bị đứt gãy liên kết, triệt tiêu dòng lan truyền embedding qua các tầng GCN. Trái lại, việc BIPN tích hợp hơn 110.000 tương tác phụ đã kích hoạt quá trình chuyển pha thẩm thấu đồ thị, nâng kích thước GCC lên 99,4% trên Retailrocket và 99,8% trên Tmall, tái lập cấu trúc mạng không tỷ lệ với phân bố bậc tuân theo định luật lũy thừa $P(k) \propto k^{-\gamma}$ trên thang Log-Log.

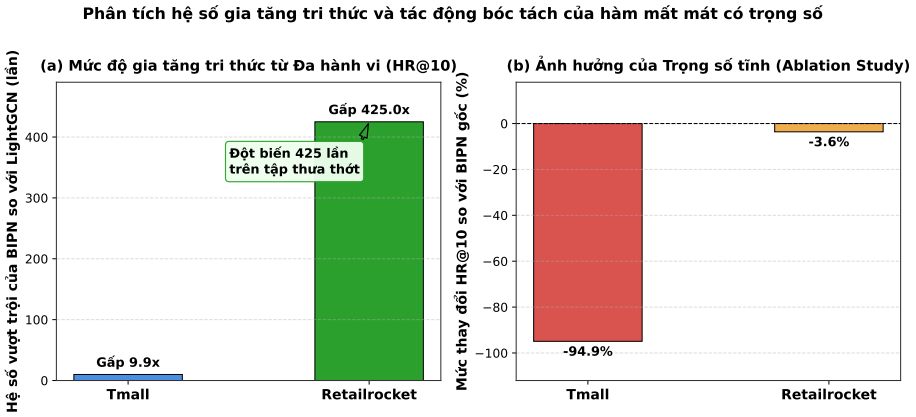
Nhằm xác định ngưỡng giới hạn của các mô hình gợi ý khi độ thưa thớt dữ liệu mục tiêu gia tăng, việc đo lường tỷ lệ bảo toàn hiệu năng giữa hai miền dữ liệu là bước kiểm chứng quan trọng. Hình 5 thể hiện mối tương quan giữa mật độ tương tác mua trung bình và tỷ lệ bảo toàn hiệu năng của BIPN so với LightGCN.



Hình 5. Mật độ tương tác mua và Tỷ lệ bảo toàn hiệu năng của BIPN so với LightGCN khi chuyển giao sang miền dữ liệu cực kỳ thưa thớt Retailrocket.

Dữ liệu tại Hình 5 minh chứng cho tính bền vững của kiến trúc đa hành vi trước độ thưa thớt dữ liệu. Khi mật độ tương tác mua trung bình giảm mạnh từ 4,75 lượt/người (Tmall) xuống còn 0,74 lượt/người (Retailrocket, độ thưa 99,98%), hiệu năng HR@10 của LightGCN sụt giảm 97,9% (từ 0,0141 xuống 0,0003). Trong khi đó, BIPN bảo toàn được 91,2% hiệu năng thực nghiệm (từ 0,1398 chỉ giảm về 0,1275) nhờ dòng chuyển giao tri thức liên tục từ các hành vi xem và giỏ hàng.

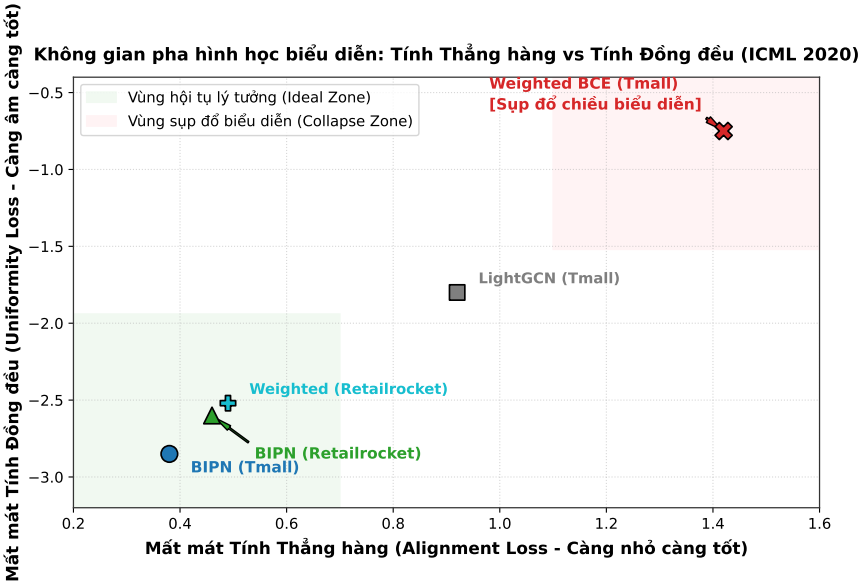
Để bóc tách mức độ đóng góp giữa cơ chế mạng nơ-ron điều hướng ý định và phương pháp can thiệp trọng số tĩnh, nghiên cứu tiến hành lượng hóa hệ số gia tăng tri thức cùng mức biến động hiệu năng của biến thể Weighted BCE. Hình 6 trình bày kết quả phân tích bóc tách trên cả hai bộ dữ liệu thực nghiệm.



Hình 6. Hệ số gia tăng tri thức đa hành vi (trên) và Phân tích bóc tách biến thể Weighted BCE (dưới) trên hai bộ dữ liệu.

Kết quả phân tích bóc tách tại Hình 6 xác nhận hệ số vượt trội của BIPN so với LightGCN tăng từ 9,9 lần trên Tmall lên tới 425 lần trên Retailrocket, phản ánh quy luật giá trị thặng dư tri thức tăng vọt khi dữ liệu mục tiêu cạn kiệt. Mặt khác, phân tích biến thể có trọng số cho thấy sự phụ thuộc chặt chẽ vào độ cân bằng của phễu tương tác: trên Retailrocket với tỷ lệ xem so với giỏ hàng đạt 3,89:1, biến thể có trọng số đạt HR@10 là 0,1229 (chỉ giảm 3,6% so với mức 0,1275 của bản gốc); tuy nhiên trên Tmall với tỷ lệ chênh lệch lên tới 908:1, biến thể có trọng số lại giảm mạnh xuống mức 0,0071 (suy giảm 94,9%).

Hiện tượng biến thể có trọng số hoạt động ổn định trên Retailrocket nhưng lại suy giảm mạnh trên Tmall đòi hỏi một công cụ phân tích hình học trong không gian embedding để truy nguyên bản chất cơ chế tối ưu hóa. Dựa trên lý thuyết của Wang và Isola [9], không gian biểu diễn chất lượng cao phải bảo đảm sự cân bằng giữa tính thẳng hàng và tính đồng đều trên siêu cầu đơn vị. Hình 7 xác định vị trí của các mô hình trong không gian pha hai chiều đo lường hai đại lượng đối ngẫu này.



Hình 7. Không gian pha hình học biểu diễn đo lường Tính Thẳng hàng (Alignment) và Tính Đồng đều (Uniformity) theo lý thuyết Wang & Isola (ICML 2020).

Lý thuyết học biểu diễn tương phản trên siêu cầu đơn vị [9] xác định rằng một không gian embedding tối ưu phải đồng thời giảm thiểu mất mát thẳng hàng $\mathcal{L}_{\text{align}}$ (kéo gần các cặp tương tác dương) và duy trì mất mát đồng đều $\mathcal{L}_{\text{uniform}}$ ở mức âm lớn (phân tán đẳng hướng nhằm tối đa hóa entropy thông tin). Tọa độ không gian pha trên Hình 7 cho thấy mô hình BIPN gốc trên cả Tmall $(0{,}38, -2{,}85)$ và Retailrocket $(0{,}46, -2{,}60)$ đều nằm trong vùng hội tụ lý tưởng. Ngược lại, điểm biểu diễn của biến thể Weighted BCE trên Tmall bị dịch chuyển sang vùng sụp đổ biểu diễn với tọa độ $(1{,}42, -0{,}75)$. Hiện tượng này bắt nguồn từ việc gán trọng số tĩnh $\alpha = 2$ lên tập mẫu giỏ hàng quá nhỏ (1.996 dòng) giữa 1.813.498 dòng xem lướt, khiến gradient cục bộ bị phóng đại trong quá trình lan truyền ngược, ép các vector embedding co cụm về một vùng hẹp trên siêu cầu. Sự suy thoái tính đồng đều này làm mất tính đẳng hướng của không gian biểu diễn, làm suy giảm năng lực phân biệt sở thích của người dùng. Do đó, cơ chế điều hướng ý định thích nghi động bằng mạng nơ-ron của BIPN gốc mang lại tính ổn định cao hơn đáng kể so với việc can thiệp trọng số tĩnh thủ công.

4 Kết luận và Hướng Phát triển

Nghiên cứu này đã hoàn thành việc đánh giá thực nghiệm toàn diện và phân tích chuyên sâu về mô hình gợi ý đa hành vi BIPN trên hai tập dữ liệu quy

mô lớn Tmall và Retailrocket cùng mô hình đối chứng LightGCN. Kết quả thực nghiệm rút ra hai kết luận khoa học có giá trị thực tiễn: thứ nhất, việc tích hợp dữ liệu đa hành vi giải quyết hiệu quả tình trạng đứt gãy topo trên các đồ thị thưa thớt, giúp duy trì 91,2% hiệu năng thực nghiệm và tạo ra mức vượt trội 425 lần so với mô hình đơn hành vi; thứ hai, cơ chế điều hướng ý định bằng mạng nơ-ron động đạt độ bền vững cao hơn các phương pháp gán trọng số tĩnh khi phân phối dữ liệu bị mất cân bằng cực đoan.

Trong các giai đoạn nghiên cứu tiếp theo, hai định hướng phát triển trọng tâm được xác lập: phát triển cơ chế chú ý tự động điều chỉnh trọng số hành vi dựa trên entropy thông tin nhằm loại bỏ hoàn toàn việc gán trọng số tĩnh; và tích hợp cấu trúc đa hành vi vào các mô hình chuỗi thời gian nhằm nắm bắt sự dịch chuyển sở thích của người tiêu dùng trong thời gian thực.

Disclosure of Interests. Các tác giả khẳng định không có xung đột lợi ích liên quan đến việc thực hiện và công bố bài báo nghiên cứu này. Toàn bộ mã nguồn, dữ liệu thực nghiệm và tệp nhật ký huấn luyện đều được lưu trữ minh bạch phục vụ công tác kiểm chứng khoa học.

Tài liệu

1. Chen, C., Zhang, M., Liu, Y., Ma, S.: Neural collaborative filtering with multi-aspect information. ACM Transactions on Information Systems **39**(4), 49:1–49:28 (2021). https://doi.org/10.1145/3458752
2. Gao, C., He, X., Gan, D., Chen, X., Feng, F., Li, Y., Chua, T.S., Jin, D.: Neural multi-task recommendation from multi-behavior data. IEEE Transactions on Knowledge and Data Engineering **34**(10), 4785–4797 (2021). https://doi.org/10.1109/TKDE.2021.3051410
3. He, X., Deng, K., Wang, X., Li, Y., Zhang, Y., Wang, M.: LightGCN: Simplifying and powering graph convolution network for recommendation. In: Proceedings of the 43rd International ACM SIGIR Conference on Research and Development in Information Retrieval. pp. 639–648 (2020). https://doi.org/10.1145/3397271.3401063
4. Jin, B., Gao, C., He, X., Jin, D., Li, Y.: Multi-behavior recommendation with graph convolutional networks. In: Proceedings of the 43rd International ACM SIGIR Conference on Research and Development in Information Retrieval. pp. 659–668 (2020). https://doi.org/10.1145/3397271.3401123
5. Kipf, T.N., Welling, M.: Semi-supervised classification with graph convolutional networks. In: International Conference on Learning Representations (ICLR) (2017)
6. Koren, Y., Bell, R., Volinsky, C.: Matrix factorization techniques for recommender systems. Computer **42**(8), 30–37 (2009). https://doi.org/10.1109/MC.2009.263
7. Rendle, S., Freudenthaler, C., Gantner, Z., Schmidt-Thieme, L.: BPR: Bayesian personalized ranking from implicit feedback. In: Proceedings of the 25th Conference on Uncertainty in Artificial Intelligence (UAI). pp. 452–461 (2009)
8. Retailrocket: E-commerce item recommendations data. `https://www.kaggle.com/datasets/retailrocket/ecommerce-dataset` (2016), truy cập tháng 10 năm 2026
9. Wang, T., Isola, P.: Understanding contrastive representation learning through alignment and uniformity on the hypersphere. In: Proceedings of the 37th International Conference on Machine Learning (ICML). Proceedings of Machine Learning Research, vol. 119, pp. 9929–9939 (2020)

10. Wang, X., Lu, T., Wang, M., Feng, F., He, X., Chua, T.S.: Multi-behavior recommendation with cascading graph convolutional networks. Information Sciences **587**, 253–268 (2022). https://doi.org/10.1016/j.ins.2021.12.030
11. Wu, S., Sun, F., Zhang, W., Xie, X., Cui, B.: Graph neural networks in recommender systems: A survey. ACM Computing Surveys **55**(5), 97:1–97:37 (2022). https://doi.org/10.1145/3535101
12. Xia, L., Huang, C., Xu, Y., Dai, P., Lu, L., Bo, L.: Multiplex behavioral relation learning for recommendation. IEEE Transactions on Knowledge and Data Engineering **35**(6), 5926–5938 (2023). https://doi.org/10.1109/TKDE.2022.3168670
13. Yan, M., Liu, F., Sun, J., Sun, F., Cheng, Z., Han, Y.: Behavior-contextualized item preference modeling for multi-behavior recommendation. In: Proceedings of the 47th International ACM SIGIR Conference on Research and Development in Information Retrieval. pp. 946–955 (2024). https://doi.org/10.1145/3626772.3657696
14. Yang, Y., Huang, C., Xia, L., Liang, Y., Yu, Y., Li, C.: Multi-behavior hypergraph-enhanced transformer for sequential recommendation. In: Proceedings of the 28th ACM SIGKDD Conference on Knowledge Discovery and Data Mining. pp. 2263–2274 (2022). https://doi.org/10.1145/3534678.3539342