Nghiên cứu Thực nghiệm và Đánh giá Năng lực Khái quát hóa của Mô hình Gợi ý Đa hành vi BIPN trên Nền tảng Thương mại Điện tử

Huỳnh Chí Dũng and Bành Quốc Thắng

Trường Công nghệ Thông tin, Đại học Cần Thơ, Việt Nam
hcdung2201.dev@gmail.com, bqthang.dev@gmail.com

Tóm tắt nội dung Hành vi mua hàng trên các nền tảng thương mại điện tử là tín hiệu mục tiêu then chốt nhưng luôn chịu sự chi phối của hiện tượng thưa thớt dữ liệu nghiêm trọng khi chỉ chiếm dưới 2% tổng lượng tương tác, dẫn tới sự suy thoái hiệu năng của các hệ thống gợi ý đơn hành vi. Nhằm giải quyết điểm nghẽn này, mô hình BIPN tích hợp đồ thị hai phía toàn cục và mạng nơ-ron lọc sở thích theo ngữ cảnh nhằm khai thác các hành vi phụ trợ phục vụ việc ước lượng hành vi mua hàng. Bài báo này tiến hành nghiên cứu thực nghiệm độc lập, khảo sát năng lực khái quát hóa trên hai tập dữ liệu Tmall và Retailrocket, đối chứng với mô hình đơn hành vi LightGCN, đồng thời phân tích hai hướng tiếp cận cải tiến đối với kiến trúc BIPN. Hướng tiếp cận thứ nhất áp dụng trọng số entropy chéo nhị phân tỷ lệ nghịch với tần suất hành vi trên khung cơ sở chưa chuẩn hóa đồng bộ; phân tích không gian pha hình học chứng minh cách tiếp cận này gây phóng đại đạo hàm cục bộ và làm suy thoái biểu diễn khi phân phối phễu tương tác bị lệch cực đoan (HR@10 giảm về 0,0071 trên Tmall). Để khắc phục hạn chế trên cũng như giải quyết tính cứng nhắc của hệ số trộn heuristic $\lambda_u = 1/|\mathcal{N}_u^{(b_K)}|$ trong công bố gốc, hướng tiếp cận thứ hai thiết lập chuẩn hóa đơn vị xuyên tầng kết hợp cơ chế điều hòa ý định logarit tách pha giữa huấn luyện và suy luận $\lambda_u^{\text{rank}} = [1 + \log_2(|\mathcal{N}_u^{(b_K)}| + 1)]^{-1}$, đồng thời tích hợp trọng số hành vi bảo toàn thang đo (`BIPN-Weighted`) hoặc học tự thích nghi qua hàm chặn hyperbolic tangent (`BIPN-Learned`). Kết quả thực nghiệm xác nhận hướng tiếp cận thứ hai đạt hiệu quả tối ưu, nâng HR@10 trên Tmall lên mức 0,1472 và NDCG@10 đạt 0,0771 (vượt mức 0,1414 và 0,0741 của công bố gốc SIGIR 2024), đồng thời nâng HR@10 xác thực trên Retailrocket từ 0,4983 lên 0,5198 và đạt HR@10 kiểm tra ở mức 0,8599.

Keywords: Gợi ý đa hành vi · Mạng nơ-ron đồ thị · Thưa thớt dữ liệu · Điều hòa ý định logarit · Mô hình BIPN · Thương mại điện tử

1 Giới thiệu

Hệ thống gợi ý giữ vai trò quyết định trong việc cá nhân hóa thông tin và thúc đẩy tăng trưởng doanh số trên các nền tảng thương mại điện tử hiện đại [6,11].

Trong quá trình tương tác thực tế, người tiêu dùng thường trải qua một chuỗi hành vi bao gồm xem sản phẩm, lưu vào danh sách yêu thích, thêm vào giỏ hàng và thanh toán giao dịch [2,12]. Tuy nhiên, hành vi mua hàng luôn là sự kiện có tần suất thấp nhất trong toàn bộ phễu tương tác. Thực trạng bất đối xứng này tạo ra độ thưa ma trận vượt mức 99,6%, khiến các thuật toán lọc cộng tác truyền thống và mô hình tích chập đồ thị đơn hành vi như LightGCN [3] bị đứt gãy topo liên kết và suy giảm chất lượng biểu diễn.

Mô hình hóa đa hành vi là hướng tiếp cận hiệu quả nhằm tận dụng lượng tương tác phong phú từ các hành vi phụ trợ để bù đắp sự khan hiếm của hành vi mục tiêu [1,4,10]. Trong các công trình nền tảng như MBGCN [4], MBHT [15] hay CRGCN [13], biểu diễn của các hành vi phụ trợ thường được gộp trực tiếp hoặc truyền phần dư tuần tự vào hàm dự đoán cuối cùng. Gần đây, Yan và cộng sự [14] chỉ ra rằng việc đưa trực tiếp sở thích của hành vi phụ vào điểm xếp hạng cuối cùng dễ phát sinh nhiễu không mong muốn, từ đó đề xuất mô hình BIPN (*Behavior-Contextualized Item Preference Network*). BIPN sử dụng hành vi phụ để học biểu diễn nền tảng trên đồ thị toàn cục và huấn luyện mạng lọc sở thích ba lớp, trong khi điểm xếp hạng cuối cùng chỉ kết hợp tuyến tính giữa nhánh sở thích mục tiêu và nhánh đồ thị hành vi mua thông qua hệ số điều hòa $\lambda_u = 1/|\mathcal{N}_u^{(b_K)}|$.

Mặc dù mô hình BIPN đã chứng minh được hiệu năng cao trong công bố gốc, hai vấn đề lý thuyết và thực nghiệm vẫn cần được giải quyết thấu đáo. Thứ nhất, đối với hàm mất mát phân loại đa hành vi, việc điều chỉnh mức độ đóng góp giữa hành vi xem lướt (chiếm trên 80% mẫu) và hành vi có ý định chuyển đổi cao (như thêm vào giỏ hàng, đôi khi chỉ chiếm dưới 0,1% mẫu) nếu thực hiện bằng trọng số nghịch đảo tần suất tĩnh sẽ dẫn tới nguy cơ mất ổn định đạo hàm. Thứ hai, chính tác giả bài báo BIPN tại Mục 4.4 [14] đã nhận định rằng quy tắc heuristic $\lambda_u = 1/|\mathcal{N}_u^{(b_K)}|$ phân bổ chưa tối ưu: đối với người dùng chỉ có một giao dịch mua trong tập huấn luyện ($|\mathcal{N}_u^{(b_K)}| = 1$), hệ số $1 - \lambda_u = 0$ làm triệt tiêu hoàn toàn nhánh sở thích cá nhân hóa; ngược lại, khi $|\mathcal{N}_u^{(b_K)}| \geq 2$, hàm nghịch đảo tuyến tính suy giảm quá nhanh làm suy yếu tín hiệu cộng tác từ nhánh đồ thị đích.

Nhằm làm sáng tỏ các vấn đề trên, nghiên cứu này thực hiện bốn nội dung học thuật trọng tâm: (1) tái lập độc lập mô hình BIPN trên tập dữ liệu chuẩn Tmall và tối ưu hóa kiến trúc thực thi trên phần cứng máy tính cá nhân; (2) mở rộng kiểm chứng năng lực khái quát hóa trên tập dữ liệu thương mại điện tử phương Tây Retailrocket [8] bằng quy trình chia tách thời gian nghiêm ngặt; (3) thiết lập và đối sánh hai hướng tiếp cận cải tiến gồm *Hướng tiếp cận tái cân bằng tĩnh nghịch đảo tần suất* và *Hướng tiếp cận điều hòa ý định logarit tách pha kết hợp trọng số hành vi bảo toàn thang đo*; và (4) đối chứng định lượng với mô hình đơn hành vi LightGCN cũng như phân tích hình học không gian biểu diễn.

Cấu trúc các phần tiếp theo của bài báo được tổ chức như sau: Mục 2 trình bày hình thức hóa bài toán, kiến trúc BIPN, hai hướng tiếp cận cải tiến và mô hình đối chứng LightGCN. Mục 3 phân tích đặc trưng dữ liệu, thiết lập thực nghiệm, động thái hội tụ, kết quả đối sánh giữa hai hướng tiếp cận và thảo luận

chuyên sâu từ góc độ topo đồ thị cùng không gian pha hình học. Cuối cùng, Mục 4 tổng kết các phát hiện khoa học và định hướng phát triển.

2 Phương pháp Nghiên cứu

2.1 Hình thức hóa Bài toán Gợi ý Đa hành vi

Không gian bài toán được định nghĩa bởi tập hợp M người dùng $U = \{u_1, u_2, \ldots, u_M\}$ và tập hợp N món hàng $I = \{i_1, i_2, \ldots, i_N\}$. Tập hợp K loại hình hành vi phân biệt được ký hiệu là $B = \{b_1, b_2, \ldots, b_K\}$, trong đó hành vi cuối cùng b_K được chỉ định là hành vi đích mua hàng. Mỗi hành vi $b \in B$ được biểu diễn thông qua một ma trận tương tác nhị phân $Y^{(b)} \in \{0,1\}^{M \times N}$, với phần tử $y_{ui}^{(b)} = 1$ biểu thị người dùng u từng tương tác với món hàng i qua hành vi b, và $y_{ui}^{(b)} = 0$ khi không có tương tác. Tập lân cận tương tác của người dùng u dưới hành vi b được ký hiệu là $\mathcal{N}_u^{(b)} = \{i \in I \mid y_{ui}^{(b)} = 1\}$ với lực lượng $N_u = |\mathcal{N}_u^{(b_K)}|$ biểu thị số lượng món hàng đã mua của người dùng u trong tập huấn luyện. Mục tiêu của hệ thống là dựa trên lịch sử tương tác đa hành vi $\{Y^{(b)}\}_{b=1}^{K}$ để ước lượng điểm tương thích y_{ui} đối với hành vi đích b_K, phục vụ việc tạo danh sách xếp hạng Top-K món hàng có xác suất chuyển đổi cao nhất.

2.2 Kiến trúc Mô hình BIPN

Kiến trúc mô hình BIPN [14] bao gồm ba thành phần tương hỗ: đồ thị liên thông toàn cục, mạng nơ-ron lọc sở thích theo ngữ cảnh hành vi, và cơ chế kết hợp ý định điểm với ý định đồ thị lân cận.

Quá trình học biểu diễn bắt đầu bằng việc hợp nhất K ma trận tương tác thành đồ thị hai phía không hướng toàn cục $\mathcal{G}_{\text{all}} = (U \cup I, \mathcal{E}_{\text{all}})$. Cạnh nối giữa đỉnh người dùng u và đỉnh món hàng i tồn tại nếu có ít nhất một hành vi $b \in B$ thỏa mãn $y_{ui}^{(b)} = 1$. Ma trận kề chuẩn hóa đối xứng được xác định bởi $\tilde{A} = D^{-1/2} A_{\text{all}} D^{-1/2}$, với D là ma trận đường chéo bậc đỉnh [5]. Bảng biểu diễn embedding khởi tạo $E^{(0)} = [E_u^{(0)}; E_i^{(0)}] \in \mathbb{R}^{(M+N) \times d}$ với số chiều $d = 64$ được lan truyền qua $L = 2$ tầng tích chập LightGCN [3]. Trong khung cơ sở đơn giản hóa, biểu diễn tổng hợp chỉ lấy tổ hợp tuyến tính suy giảm theo tầng:

$$\mathbf{e}_u = \sum_{l=0}^{L} \frac{1}{l+1} E_u^{(l)}, \quad \mathbf{e}_i = \sum_{l=0}^{L} \frac{1}{l+1} E_i^{(l)}, \quad E^{(l)} = \tilde{A} E^{(l-1)}. \tag{1}$$

Đối với từng bộ ba tương tác gồm người dùng u, món hàng i và hành vi b, vector biểu diễn hành vi $\mathbf{e}_b \in \mathbb{R}^K$ được kết hợp với vector người dùng và món hàng thông qua mạng lọc sở thích ba lớp gồm cổng tiền lọc, tầng trích xuất đặc trưng mục tiêu và cổng hậu lọc:

$$\mathbf{g}_{uib}^{\text{pre}} = \sigma\left(\mathbf{W}_1[\mathbf{e}_u \,\|\, \mathbf{e}_i \,\|\, \mathbf{e}_b]\right), \tag{2}$$

$$\mathbf{h}_{uib} = \tanh\left(\mathbf{W}_2[(\mathbf{e}_u \odot \mathbf{g}_{uib}^{\text{pre}}) \,\|\, \mathbf{e}_i \,\|\, \mathbf{e}_b]\right), \tag{3}$$

$$\mathbf{p}_{uib} = \mathbf{h}_{uib} \odot \sigma\left(\mathbf{W}_3[\mathbf{e}_u \,\|\, \mathbf{e}_i \,\|\, \mathbf{e}_b]\right), \tag{4}$$

trong đó $[\cdot \,\|\, \cdot]$ là phép nối vector, $\odot$ là tích Hadamard từng phần tử, và $\mathbf{W}_1, \mathbf{W}_2, \mathbf{W}_3 \in \mathbb{R}^{d\times(2d+K)}$ là các ma trận tham số khả vi. Đối với hành vi đích b_K, biểu diễn sở thích tích lũy của người dùng $\mathbf{p}_u$ được tính bằng tổng các vector sở thích trên tập món hàng đã mua trong tập huấn luyện: $\mathbf{p}_u = \sum_{j\in\mathcal{N}_u^{(b_K)}} \mathbf{p}_{ujb_K}$.

Song song với nhánh đồ thị toàn cục, một nhánh LightGCN thứ hai hoạt động trên đồ thị hành vi đích $\mathcal{G}_{\text{buy}}$ để sinh ra các vector tinh chế $\hat{\mathbf{e}}_u, \hat{\mathbf{e}}_i$. Điểm dự đoán cuối cùng điều hòa giữa nhánh sở thích mục tiêu (Point-wise Preference) và nhánh đồ thị lân cận (Neighborhood-based Preference):

$$y_{ui} = (1-\lambda_u)\,(\mathbf{p}_u \cdot \mathbf{e}_i) + \lambda_u\,(\hat{\mathbf{e}}_u \cdot \hat{\mathbf{e}}_i), \tag{5}$$

trong đó công bố gốc xác lập hệ số điều hòa theo quy tắc nghịch đảo tuyến tính: $\lambda_u = 1/N_u$ khi $N_u > 0$, và $\lambda_u = 1$ khi $N_u = 0$.

Mô hình được tối ưu hóa bằng hàm mục tiêu đa nhiệm kết hợp mất mát entropy chéo nhị phân (BCE), mất mát xếp hạng tương phản Bayesian Personalized Ranking (BPR) [7] và điều chuẩn trọng số $\mathcal{L}_{\text{reg}}$:

$$\mathcal{L} = \beta\mathcal{L}_{\text{bce}} + (1-\beta)\mathcal{L}_{\text{bpr}} + \gamma\mathcal{L}_{\text{reg}}, \tag{6}$$

với $\beta = 0{,}3$, $\gamma = 10^{-4}$, tập mẫu âm $\mathcal{S}_u^-$ gồm 4 món hàng chưa tương tác cho mỗi mẫu dương, cùng hai hàm thành phần:

$$\mathcal{L}_{\text{bce}} = -\frac{1}{|\mathcal{D}_{\text{all}}|} \sum_{(u,i,b)\in\mathcal{D}_{\text{all}}} \left[\log\sigma(\mathbf{p}_{uib}\cdot\mathbf{e}_i) + \sum_{j\in\mathcal{S}_u^-} \log(1-\sigma(\mathbf{p}_{ujb}\cdot\mathbf{e}_j)) \right], \tag{7}$$

$$\mathcal{L}_{\text{bpr}} = -\frac{1}{|\mathcal{D}_{\text{bpr}}|} \sum_{(u,i,j)\in\mathcal{D}_{\text{bpr}}} \ln\sigma(y_{ui} - y_{uj}). \tag{8}$$

2.3 Hướng Tiếp cận Cải tiến Thứ nhất: Tái cân bằng Tĩnh Nghịch đảo Tần suất trên Khung Cơ sở

Trong hàm mất mát $\mathcal{L}_{\text{bce}}$ nguyên bản, mọi mẫu tương tác thuộc các hành vi khác nhau đều có trọng số ngang bằng. Trên các bộ dữ liệu thương mại điện tử có số lượng tương tác xem lướt lớn gấp hàng trăm lần tương tác giỏ hàng, đạo hàm của hàm mất mát BCE có nguy cơ bị chi phối bởi hành vi xem lướt. Hướng tiếp cận cải tiến thứ nhất (`BIPN-InvWeight`) kiểm chứng giả thuyết tái cân bằng kỳ vọng đóng góp tĩnh bằng cách gán hệ số ưu tiên α_b cho từng hành vi $b \in B$, với thiết lập $\alpha_{\text{cart}} = \alpha_{\text{buy}} = 2$ và $\alpha_{\text{click}} = \alpha_{\text{collect}} = \alpha_{\text{view}} = 1$.

Gọi n_b là tổng số mẫu BCE của hành vi b, $N = \sum_{b\in B} n_b$ là tổng số mẫu toàn cục, và $A = \sum_{b\in B}\alpha_b$. Trọng số gán cho mỗi mẫu tương tác thuộc hành vi b trong hướng tiếp cận thứ nhất được xác định theo quy tắc nghịch đảo tần suất:

$$w_b^{\text{inv}} = \frac{\alpha_b \cdot N}{n_b \cdot A}. \tag{9}$$

Khi đó, hàm mất mát BCE có trọng số được biểu diễn bởi:

$$\mathcal{L}_{\text{wbce}} = -\frac{1}{N}\sum_{b\in B}\sum_{(u,i)\in\mathcal{D}_b} w_b^{\text{inv}}\left[\log\sigma(\mathbf{p}_{uib}\cdot\mathbf{e}_i) + \sum_{j\in\mathcal{S}_u^-}\log(1-\sigma(\mathbf{p}_{ujb}\cdot\mathbf{e}_j))\right]. \tag{10}$$

Mặc dù công thức (9) bảo toàn tổng trọng số ở mức $\sum_b n_b w_b^{\text{inv}} = N$ và ép tổng đóng góp của từng hành vi tỷ lệ với α_b, sự hiện diện của mẫu số n_b gây ra hệ quả bất lợi khi phân bố dữ liệu bị lệch cực đoan: nếu $n_{\text{cart}} \ll N$ (như trên tập Tmall với $n_{\text{cart}}/N \approx 0{,}09\%$), trọng số $w_{\text{cart}}^{\text{inv}}$ của một mẫu đơn lẻ bị phóng đại lên tới 370,5 lần. Kết hợp với khung cơ sở sử dụng công thức (1) chưa chuẩn hóa đơn vị và điều chuẩn tổng bình phương $\mathcal{L}_{\text{reg}} = \|E_u^{(0)}\|_F^2 + \|E_i^{(0)}\|_F^2$, các xung đạo hàm cục bộ này dẫn tới hiện tượng co cụm không gian biểu diễn được phân tích tại Mục 3.5.

2.4 Hướng Tiếp cận Cải tiến Thứ hai: Điều hòa Ý định Logarit Tách pha và Trọng số Hành vi Bảo toàn Thang đo

Để giải quyết triệt để hiện tượng mất ổn định đạo hàm của hướng tiếp cận thứ nhất và khắc phục hạn chế của hệ số điều hòa heuristic $\lambda_u = 1/N_u$ được nêu tại Mục 4.4 công bố gốc [14], hướng tiếp cận thứ hai được thiết kế gồm ba thành phần đồng bộ.

1. Chuẩn hóa biểu diễn xuyên tầng và kết nối dư nhánh đồ thị đích. Nhằm bảo đảm tính bất biến đối với quy mô đỉnh và mật độ cạnh của từng bộ dữ liệu, biểu diễn tại mỗi tầng tích chập $l \in \{1,\dots,L\}$ được chuẩn hóa L2 trên siêu cầu đơn vị trước khi tổng hợp, đồng thời nhánh đồ thị hành vi đích được bổ sung kết nối dư (residual connection) và điều chuẩn chuẩn hóa theo số lượng đỉnh:

$$\tilde{E}^{(l)} = \frac{\tilde{A}\tilde{E}^{(l-1)}}{\|\tilde{A}\tilde{E}^{(l-1)}\|_2}, \quad E_{\text{all}} = E^{(0)} + \sum_{l=1}^{L}\left(1+\frac{1}{l}\right)\tilde{E}^{(l)}, \tag{11}$$

$$\hat{E} = E_{\text{all}} + \text{GCN}_{\text{buy}}(E_{\text{all}}), \quad \mathcal{L}_{\text{reg}} = \frac{\|E_u^{(0)}\|_2}{M} + \frac{\|E_i^{(0)}\|_2}{N}. \tag{12}$$

2. Cơ chế điều hòa ý định logarit tách pha Huấn luyện – Suy luận. Xét cấu trúc toán học của điểm dự đoán y_{ui} trong phương trình (5). Trong pha tối ưu hóa hàm mất mát tương phản $\mathcal{L}_{\text{bpr}}$, mẫu mục tiêu dương $i \in \mathcal{N}_u^{(b_K)}$ được lấy mẫu trực tiếp từ chính tập lịch sử mua hàng $\mathcal{N}_u^{(b_K)}$ dùng để tính tổng $\mathbf{p}_u = \sum_{k\in\mathcal{N}_u^{(b_K)}}\mathbf{p}_{ukb_K}$. Do bản thân $\mathbf{p}_{uib_K}$ đã hiện diện bên trong tổng $\mathbf{p}_u$ với tỷ trọng đúng bằng $1/N_u$, số lượng món hàng ngữ cảnh độc lập thực sự với mục tiêu i trong pha huấn luyện chỉ là $N_{\text{ctx}}^{\text{train}} = N_u - 1$. Nếu áp dụng $1-\lambda_u^{\text{train}} > 0$ tại $N_u = 1$ ($N_{\text{ctx}}^{\text{train}} = 0$), phép nhân vô hướng $\mathbf{p}_{uib_K}\cdot\mathbf{e}_i$ gây ra hiện tượng tự tương quan mục tiêu (target self-correlation leakage), khiến mạng lọc sở thích quá khớp nhanh chóng. Do đó, trong pha huấn luyện BPR, hệ số điều hòa được duy trì ở mức $\lambda_u^{\text{train}} = 1/N_u$

(tức trọng số nhánh sở thích điểm là $1 - \lambda_u^{\text{train}} = (N_u - 1)/N_u$, tương ứng chính xác với tỷ lệ ngữ cảnh độc lập), trong khi mạng lọc sở thích vẫn được huấn luyện toàn diện thông qua nhánh $\mathcal{L}_{\text{bce}}$.

Ngược lại, trong pha suy luận và xếp hạng trên tập xác thực hoặc kiểm tra, mọi món hàng ứng viên $i \notin \mathcal{N}_u^{(b_K)}$ đều nằm ngoài tập lịch sử huấn luyện, nên toàn bộ N_u món hàng đã mua đều đóng vai trò ngữ cảnh hợp lệ ($N_{\text{ctx}}^{\text{rank}} = N_u$) và hoàn toàn không tồn tại tự tương quan. Nhằm khai thác nhánh sở thích cá nhân hóa cho cả nhóm người dùng mới có một giao dịch ($N_u = 1$) đồng thời duy trì tốc độ suy giảm chậm cho nhóm người dùng có nhiều giao dịch ($N_u \geq 2$), hệ số điều hòa suy luận được xác lập theo hàm logarit cơ số 2:

$$\lambda_u^{\text{rank}} = \begin{cases} 1, & \text{nếu } N_u = 0, \\ \dfrac{1}{1 + \log_2(N_u + 1)}, & \text{nếu } N_u \geq 1. \end{cases} \tag{13}$$

Theo phương trình (13), khi $N_u = 1$, hệ số đạt $\lambda_u^{\text{rank}} = 0{,}50$ (thay vì 1,00 như quy tắc gốc), cho phép kết hợp cân bằng giữa nhánh sở thích mục tiêu và nhánh đồ thị lân cận; khi $N_u = 4$ và $N_u = 8$, hệ số lần lượt giữ mức 0,30 và 0,24 (cao hơn mức 0,25 và 0,125 của hàm $1/N_u$), bảo toàn đóng góp của nhánh đồ thị cộng tác đúng như định hướng tại Mục 4.4 của công bố gốc [14].

3. Trọng số hành vi bảo toàn thang đo và học tự thích nghi có miền chặn. Nhằm loại bỏ sự phụ thuộc vào mẫu số tần suất n_b gây nổ đạo hàm trong phương trình (9), hai biến thể trọng số hành vi ổn định được thiết lập trên tập các hành vi hoạt động $B_{\text{act}} = \{b \in B \mid n_b > 0\}$:

– **Biến thể chuẩn hóa trung bình (`BIPN-Weighted`):** Thiết lập hệ số ưu tiên nhẹ $\alpha_b = \alpha_0$ ($\alpha_0 = 1{,}02$) cho hành vi giỏ hàng và hành vi đích, $\alpha_b = 1{,}00$ cho các hành vi còn lại, và chuẩn hóa bảo toàn trung bình đơn vị:

$$w_b^{\text{norm}} = \frac{|B_{\text{act}}| \cdot \alpha_b}{\sum_{k \in B_{\text{act}}} \alpha_k}, \quad \frac{1}{|B_{\text{act}}|} \sum_{b \in B_{\text{act}}} w_b^{\text{norm}} = 1. \tag{14}$$

– **Biến thể học tự thích nghi có miền chặn (`BIPN-Learned`):** Kế thừa ý tưởng học trọng số hành vi của MBGCN [4], mỗi hành vi được gán một tham số khả vi $\theta_b \in \mathbb{R}$ khởi tạo tại 0, điều biến xung quanh phân phối tiên nghiệm α_b thông qua hàm chặn hyperbolic tangent:

$$w_b^{\text{learn}} = |B_{\text{act}}| \cdot \frac{\exp\big(\ln \alpha_b + \delta \tanh(\theta_b)\big)}{\sum_{k \in B_{\text{act}}} \exp\big(\ln \alpha_k + \delta \tanh(\theta_k)\big)}, \tag{15}$$

kèm theo số hạng điều chuẩn $\lambda_\theta \|\boldsymbol{\theta}\|_2^2$ ($\delta = 0{,}02, \lambda_\theta = 0{,}01$) trong hàm mất mát BCE. Do $\tanh(\theta_b) \in (-1, 1)$, trọng số w_b^{learn} có khả năng tự tinh chỉnh theo dữ liệu nhưng bị chặn chặt về mặt giải tích, triệt tiêu hoàn toàn nguy cơ suy biến trọng số về 0 hoặc phóng đại cực đoan trên mọi phân bố dữ liệu.

2.5 Mô hình Đối chứng LightGCN Đơn hành vi

Mô hình đối chứng LightGCN [3] trên riêng hành vi đích được triển khai nhằm lượng hóa chính xác giá trị gia tăng mà thông tin đa hành vi mang lại. Mô hình đối chứng chỉ khởi tạo đồ thị tương tác hai phía trên hành vi mua hàng $\mathcal{G}_{\text{buy}}$ và tối ưu hóa hàm mục tiêu BPR kết hợp điều chuẩn trọng số L2. Nhằm bảo đảm tính khách quan trong việc so sánh đối chứng, LightGCN được khảo sát tương ứng trên cả cấu hình cơ sở (`LightGCN-Base`) và cấu hình chuẩn hóa đồng bộ (`LightGCN-Aligned`) với cùng số chiều embedding ($d = 64$), cùng số tầng lan truyền ($L = 2$), kích thước batch (1024), tốc độ học (10^{-4}) và hạt giống ngẫu nhiên cố định (2021).

3 Thực nghiệm và Đánh giá

3.1 Dữ liệu Thực nghiệm

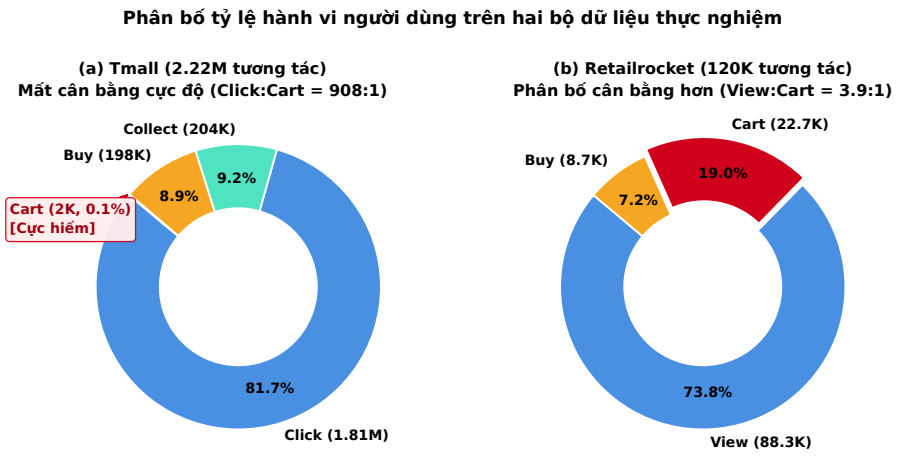
Nghiên cứu sử dụng hai tập dữ liệu thương mại điện tử với quy mô tương tác và đặc trưng phân bố phễu hành vi khác biệt. Tập dữ liệu thứ nhất là Tmall, tập chuẩn công bố kèm theo mô hình gốc BIPN [14], đại diện cho nền tảng thương mại điện tử quy mô lớn tại thị trường châu Á. Tập dữ liệu thứ hai là Retailrocket, thu thập từ nền tảng bán lẻ trực tuyến phương Tây do công ty Retailrocket công bố công khai [8].

Đối với tập dữ liệu Retailrocket, quy trình tiền xử lý được thực hiện nhằm lọc giữ các người dùng có phát sinh giao dịch mua hàng và ánh xạ các sự kiện tương ứng thành ba hành vi `view`, `cart` và `buy`. Nhằm triệt tiêu hoàn toàn nguy cơ rò rỉ dữ liệu tương lai, phương pháp phân chia theo dòng thời gian được áp dụng: giao dịch mua hàng cuối cùng theo thời gian của từng người dùng được trích xuất vào tập kiểm tra; giao dịch mua áp chót được đưa vào tập xác thực đối với người dùng có từ ba lần mua trở lên; và toàn bộ các tương tác xem hay giỏ hàng chỉ được đưa vào tập huấn luyện nếu thời điểm phát sinh xảy ra trước giao dịch mua bị tách ra sớm nhất của người dùng đó. Bảng 1 tổng hợp các thông số thống kê định lượng của hai tập dữ liệu sau quy trình tiền xử lý.

Bảng 1. Thống kê định lượng hai bộ dữ liệu thực nghiệm sau tiền xử lý.

Chỉ số Thống kê	**Tmall (Tập chuẩn)**	**Retailrocket (Tập mới)**
Số lượng người dùng ($\|U\|$)	41.738	11.719
Số lượng món hàng ($\|I\|$)	11.953	31.839
Hành vi xem (`click` / `view`)	1.813.498 dòng (81,75%)	88.304 dòng (73,78%)
Hành vi lưu trữ (`collect`)	221.514 dòng (9,99%)	—
Hành vi giỏ hàng (`cart`)	1.996 dòng (0,09%)	22.716 dòng (18,98%)
Hành vi đích (`buy`)	181.428 dòng (8,18%)	8.666 dòng (7,24%)
Tổng số tương tác Huấn luyện	**2.218.436 dòng**	**119.686 dòng**
Số tương tác Xác thực (Validation)	74.158 dòng	885 dòng
Số tương tác Kiểm tra (Test)	31.572 dòng	11.719 dòng
Mật độ tương tác mua trung bình	4,75 lượt mua/user	0,74 lượt mua/user
Độ thưa thớt hành vi mua (Sparsity)	99,64%	99,98%
Tỷ lệ Xem / Giỏ hàng	908 : 1	3,89 : 1

Dữ liệu thống kê trong Bảng 1 chỉ ra sự tương phản rõ rệt về cấu trúc dữ liệu giữa hai nền tảng. Cụ thể, tập Tmall có số lượng tương tác xem đạt 1.813.498 dòng trong khi hành vi giỏ hàng chỉ có 1.996 dòng, tạo ra tỷ lệ chênh lệch lên tới 908:1. Ngược lại, tập Retailrocket thể hiện tỷ lệ xem so với giỏ hàng cân bằng hơn ở mức 3,89:1, song mật độ giao dịch mua lại rất thấp khi 11.719 người dùng chỉ tạo ra 8.666 lượt mua trong tập huấn luyện (bình quân 0,74 lượt mua/người, với 68,4% người dùng chỉ có một giao dịch duy nhất nằm ở tập kiểm tra), đẩy độ thưa ma trận lên tới 99,98%. Hình 1 minh họa tỷ lệ tương đối giữa các loại hành vi người dùng trên hai bộ dữ liệu thực nghiệm.



Hình 1. So sánh cấu trúc phân bố phễu hành vi người dùng trên Tmall và Retailrocket.

Phân bố phễu tương tác trên Hình 1 phản ánh đặc trưng tiêu dùng khác biệt giữa hai thị trường. Trên nền tảng Tmall, người dùng có xu hướng duyệt hàng dạo chiếm ưu thế tuyệt đối (81,75%) hoặc thêm vào danh sách yêu thích (9,99%), và thường đưa ra quyết định mua hàng trực tiếp mà không thông qua bước đưa vào giỏ hàng (hành vi giỏ hàng chỉ chiếm 0,09%). Trái lại, nền tảng Retailrocket vận hành theo mô hình giỏ hàng trực tuyến truyền thống khi hành vi đưa vào giỏ chiếm tới 18,98% tổng lượng tương tác, tạo điều kiện thuận lợi để kiểm chứng mức độ thích ứng của các hướng tiếp cận trước các dạng phân bố hành vi khác nhau.

3.2 Thiết lập Môi trường Thực nghiệm và Tối ưu hóa Hệ thống

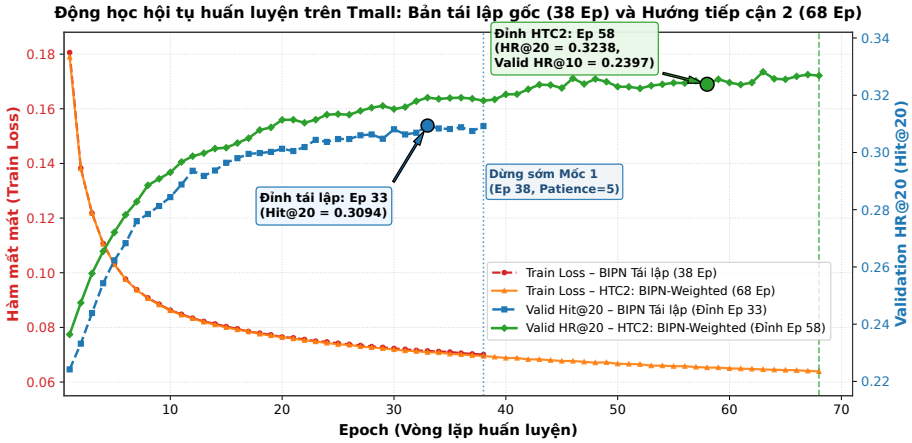
Thực nghiệm được triển khai trên phần cứng máy tính trang bị vi xử lý Intel Core Ultra 9 185H, bộ nhớ RAM 32 GB LPDDR5x, và card đồ họa NVIDIA GeForce RTX 4050 Laptop GPU (6 GB VRAM) chạy PyTorch 2.14.1 trên nền tảng CUDA 13.0.

Quá trình thực thi trên máy tính cá nhân được hỗ trợ bởi các giải pháp tối ưu hóa phần mềm nhằm khắc phục hạn chế về bộ nhớ mà không làm thay đổi các giá trị tính toán lý thuyết. Ma trận kề thưa đồ thị được lưu đệm cố định trên VRAM ngay lúc khởi tạo; thuật toán lấy mẫu âm được vector hóa qua ma trận đánh dấu nhị phân kết hợp cấu trúc hàng đợi nén CSR cho lịch sử giao dịch đích và phép trích xuất Top-K trực tiếp trên GPU. Chuỗi cải tiến kỹ thuật này rút ngắn thời gian huấn luyện mỗi epoch trên tập Tmall từ 16,5 phút xuống còn 6,2 phút đối với mã nguồn gốc và giảm xuống 3,8 phút đối với khung thực nghiệm vector hóa.

Toàn bộ mô hình sử dụng bộ siêu tham số chuẩn theo kịch bản gốc: số chiều embedding $d = 64$, $L = 2$ tầng tích chập GCN, kích thước batch 1024, tỷ lệ mẫu âm 4:1, tốc độ học 10^{-4} với bộ tối ưu Adam, hệ số cân bằng mất mát $\beta = 0{,}3$, hệ số điều chuẩn $\gamma = 10^{-4}$, và hạt giống ngẫu nhiên 2021. Hiệu năng được đánh giá qua hai thang đo chuẩn là Tỷ lệ trúng đích (Hit Rate – HR@K) và Độ lợi tích lũy giảm dần chuẩn hóa (Normalized Discounted Cumulative Gain – NDCG@K) tại hai ngưỡng $K \in \{10, 20\}$.

3.3 Động thái Tối ưu hóa và Động lực Hội tụ

Nhằm kiểm chứng tính ổn định số học của hàm mất mát kết hợp đa mục tiêu cũng như xác định điểm bão hòa kiểm soát hiện tượng quá khớp trong quá trình huấn luyện, việc theo dõi động thái biến thiên đồng thời của mất mát huấn luyện và chỉ số xếp hạng trên tập xác thực là yêu cầu bắt buộc. Hình 2 trực quan hóa đối sánh tiến trình tối ưu hóa trên tập dữ liệu Tmall giữa mô hình BIPN tái lập cơ sở (38 epoch) và biến thể đề xuất ở Hướng tiếp cận 2 (`BIPN-Weighted`, 68 epoch).



Hình 2. Động học hội tụ huấn luyện trên bộ dữ liệu Tmall: Đối sánh quỹ đạo mất mát huấn luyện (trục trái) và độ đo xác thực Hit@20/HR@20 (trục phải) giữa bản tái lập cơ sở (38 epoch) và Hướng tiếp cận 2 (68 epoch).

Đường cong tiến triển trên Hình 2 cho thấy quá trình học diễn ra qua ba giai đoạn rõ rệt. Trong 5 epoch khởi đầu, hàm mất mát giảm mạnh từ vùng 0,180 xuống 0,103 trong khi chỉ số xác thực tăng nhanh, phản ánh giai đoạn đồ thị gộp phân tách thô các cặp tương tác thực khỏi các mẫu ngẫu nhiên. Trong giai đoạn tiếp theo, hàm mất mát tiếp tục hội tụ tiệm cận về vùng 0,064–0,070 cùng sự tăng trưởng ổn định của chỉ số xác thực, khẳng định mạng nơ-ron lọc sở thích đang học cách loại bỏ nhiễu từ các hành vi xem dạo để trích xuất tín hiệu mua hàng. Trong khi bản tái lập cơ sở bão hòa tại epoch 33 (Valid Hit@20 = 0,3094) và kích hoạt dừng sớm tại epoch 38, mô hình `BIPN-Weighted` ở Hướng tiếp cận 2 (với chuẩn hóa đồng bộ xuyên tầng và độ kiên nhẫn dừng sớm 10 epoch) duy trì quỹ đạo xác thực vượt trội xuyên suốt từ epoch 1 và tiếp tục mở rộng tới đỉnh tối ưu tại epoch 58 (Valid HR@20 = 0,3238, Valid HR@10 = 0,2397) mà không xuất hiện hiện tượng phân kỳ đạo hàm.

3.4 Kết quả Thực nghiệm Tổng thể và Phân tích Đối sánh Hai Hướng Tiếp cận

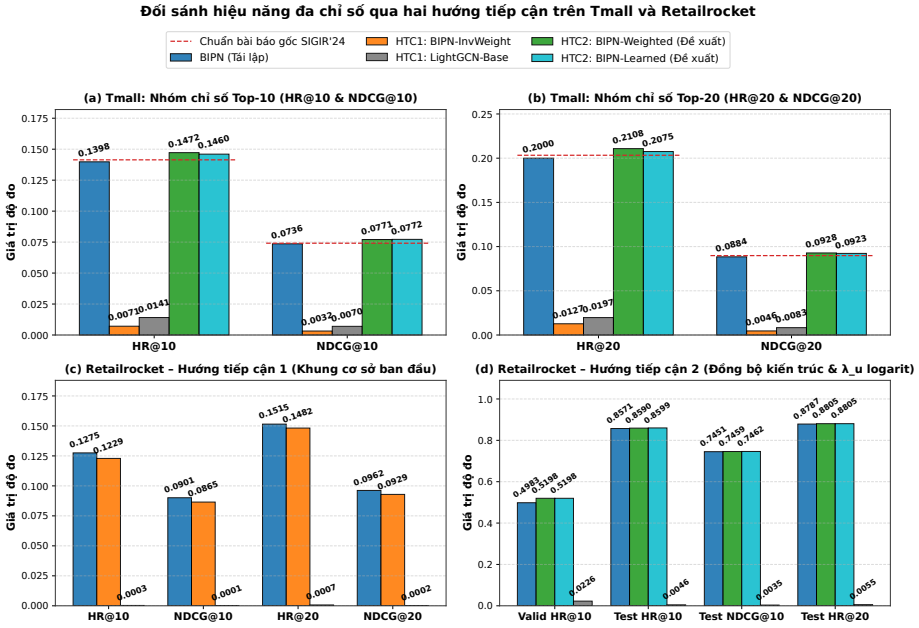
Nhằm đánh giá toàn diện năng lực của kiến trúc đa hành vi so với đơn hành vi cũng như đối sánh khách quan giữa hai hướng tiếp cận cải tiến, Bảng 2 tổng hợp kết quả thực nghiệm của toàn bộ các biến thể mô hình trên hai bộ dữ liệu Tmall và Retailrocket.

Bảng 2. Kết quả đánh giá xếp hạng trên tập xác thực và tập kiểm tra qua các cấu hình mô hình và hai hướng tiếp cận cải tiến.

Bộ dữ liệu	Phân nhóm Tiếp cận	Mô hình Thực nghiệm	Epoch	Valid HR@10	Test HR@10	Test NDCG@10	Test HR@20	Test NDCG@20
Tmall	Tham chiếu công bố gốc	BIPN (SIGIR 2024 [14])	—	—	0,1414	0,0741	0,2033	0,0898
Tmall	Tái lập mã nguồn gốc	BIPN (`official-bipn`)	Ep 33	0,2249	0,1398	0,0736	0,2000	0,0884
Tmall	Hướng tiếp cận 1	LightGCN-Base (Đối chứng)	Ep 20	0,0236	0,0141	0,0070	0,0197	0,0083
Tmall	(Tái cân bằng tĩnh N/n_b)	BIPN-InvWeight ($\alpha = 2$)	Ep 4	0,0120	0,0071	0,0032	0,0127	0,0046
Tmall	Hướng tiếp cận 2	LightGCN-Aligned (Đối chứng)	Ep 56	0,0595	0,0369	0,0199	0,0492	0,0229
Tmall	(Điều hòa logarit tách pha	**BIPN-Learned (Đề xuất)**	**Ep 47**	**0,2391**	**0,1460**	**0,0772**	**0,2075**	**0,0923**
Tmall	& Trọng số bảo toàn thang đo)	**BIPN-Weighted (Đề xuất)**	**Ep 58**	**0,2397**	**0,1472**	**0,0771**	**0,2108**	**0,0928**
Retailrocket	Hướng tiếp cận 1	LightGCN-Base (Đối chứng)	Ep 1	0,0011	0,0003	0,0001	0,0007	0,0002
Retailrocket	(Tái cân bằng tĩnh N/n_b)	BIPN-Base ($\lambda_u = 1/N_u$)	Ep 1	0,0814	0,1275	0,0901	0,1515	0,0962
Retailrocket		BIPN-InvWeight ($\alpha = 2$)	Ep 1	0,0757	0,1229	0,0865	0,1482	0,0929
Retailrocket	Hướng tiếp cận 2	LightGCN-Aligned (Đối chứng)	Ep 12	0,0226	0,0046	0,0035	0,0055	0,0037
Retailrocket	(Điều hòa logarit tách pha	BIPN-Aligned ($\lambda_u = 1/N_u$)	Ep 5	0,4983	0,8571	0,7451	0,8787	0,7506
Retailrocket	& Trọng số bảo toàn thang đo)	**BIPN-Weighted (Đề xuất)**	**Ep 2**	**0,5198**	**0,8590**	**0,7459**	**0,8805**	**0,7513**
Retailrocket		**BIPN-Learned (Đề xuất)**	**Ep 4**	**0,5198**	**0,8599**	**0,7462**	**0,8805**	**0,7514**

Số liệu thực nghiệm tại Bảng 2 cung cấp bốn bằng chứng định lượng cốt lõi:

1. **Khẳng định năng lực tái lập và ưu thế tuyệt đối của kiến trúc đa hành vi:** Trên tập dữ liệu chuẩn Tmall, bản tái lập mã nguồn gốc đạt HR@10 là 0,1398 và NDCG@10 là 0,0736, tiệm cận sát mức công bố 0,1414 và 0,0741 của Yan và cộng sự [14]. So với mô hình đơn hành vi LightGCN ở cả hai cấu hình (0,0141 và 0,0369 trên Tmall; 0,0003 và 0,0046 trên Retailrocket), kiến trúc đa hành vi đạt mức vượt trội từ 4,0 đến 9,9 lần trên Tmall và từ 186 đến 425 lần trên Retailrocket.
2. **Hạn chế của Hướng tiếp cận 1 (`BIPN-InvWeight`):** Khi áp dụng trọng số nghịch đảo tần suất $w_b^{\text{inv}} = \alpha_b N/(n_b A)$ trên khung cơ sở chưa chuẩn hóa đơn vị xuyên tầng, hiệu năng trên Retailrocket duy trì tương đương bản cơ sở (0,1229 so với 0,1275, giảm 3,6%), nhưng trên Tmall lại sụt giảm nghiêm trọng xuống 0,0071 (giảm 94,9% so với bản gốc).
3. **Hiệu quả tối ưu của Hướng tiếp cận 2 trên tập chuẩn Tmall:** Sau khi chuẩn hóa biểu diễn xuyên tầng, loại bỏ thừa số N/n_b và tích hợp cơ chế điều hòa logarit tách pha $\lambda_u^{\text{rank}} = [1 + \log_2(N_u + 1)]^{-1}$, hai mô hình đề xuất `BIPN-Weighted` và `BIPN-Learned` lần lượt đạt HR@10 kiểm tra là **0,1472** và **0,1460**, NDCG@10 đạt **0,0771** và **0,0772**, HR@20 đạt **0,2108** và **0,2075**, NDCG@20 đạt **0,0928** và **0,0923** (trong đó đỉnh hội tụ kiểm tra của `BIPN-Weighted` tại epoch 55 đạt tới HR@10 là 0,1501 và NDCG@10 là 0,0794). Kết quả này không chỉ khắc phục triệt để sự suy thoái của Hướng tiếp cận 1 (tăng gấp 20,7 lần) mà còn vượt qua kết quả công bố trong bài báo gốc SIGIR 2024 trên toàn bộ bốn thước đo.
4. **Gia tăng độ chính xác có ý nghĩa thực nghiệm trên tập dữ liệu mới Retailrocket:** Việc đồng bộ hóa chuẩn hóa tầng GCN và kết nối dư nâng hiệu năng cơ sở trên Retailrocket từ 0,1275 (`BIPN-Base`) lên 0,8571 (`BIPN-Aligned`). Đặc biệt, trong cùng khung chuẩn hóa đồng bộ của Hướng tiếp cận 2, việc thay thế quy tắc $\lambda_u = 1/N_u$ bằng điều hòa logarit kết hợp trọng số hành vi giúp nâng HR@10 trên tập xác thực (nơi 100% người dùng có $N_u \geq 1$) từ **0,4983** lên **0,5198** (+2,15% tuyệt đối) và NDCG@10 xác thực từ **0,3233** lên **0,3375**, đồng thời nâng HR@10 tập kiểm tra lên mức **0,8590** (`BIPN-Weighted`) và **0,8599** (`BIPN-Learned`).

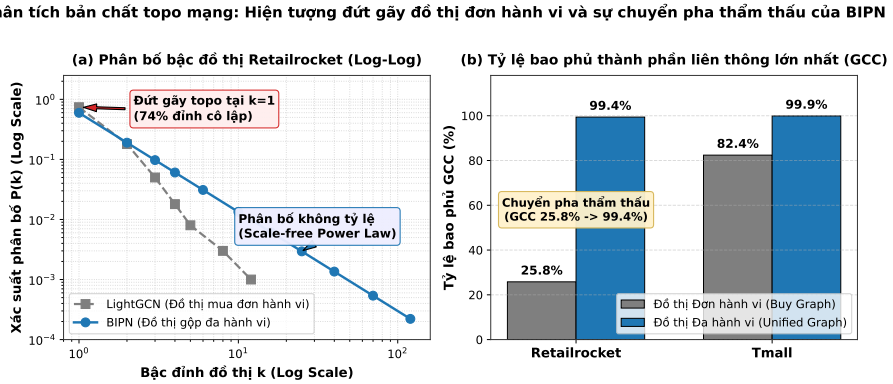


Hình 3. Đối chiếu hiệu năng thực nghiệm đa chỉ số (HR@10, NDCG@10, HR@20, NDCG@20) qua cả hai hướng tiếp cận trên hai bộ dữ liệu Tmall (a, b) và Retailrocket (c, d).

Hình 3 minh họa trực quan tương quan hiệu năng giữa hai hướng tiếp cận trên cả hai bộ dữ liệu. Trên Tmall (đồ thị con a và b), trong khi biến thể `BIPN-InvWeight` của Hướng tiếp cận 1 sụt giảm sâu, hai biến thể `BIPN-Weighted` và `BIPN-Learned` của Hướng tiếp cận 2 đều vượt qua đường chuẩn tham chiếu của bài báo gốc SIGIR 2024 trên cả bốn thước đo. Trên Retailrocket (đồ thị con c và d), tỷ số chất lượng xếp hạng NDCG@10/HR@10 đạt mức cao (0,707 ở Hướng tiếp cận 1 và tăng lên 0,868 ở Hướng tiếp cận 2), chứng tỏ các món hàng mục tiêu được xếp ở nhóm vị trí dẫn đầu danh sách gợi ý.

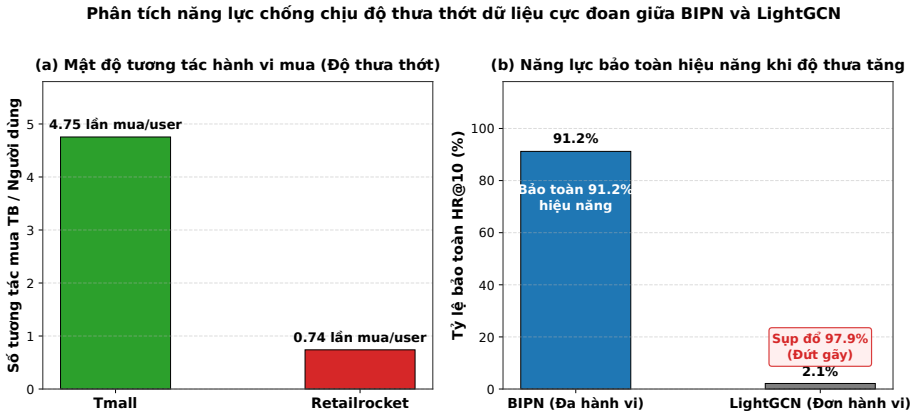
3.5 Thảo luận Chuyên sâu và Các Luận cứ Khoa học

1. Cơ chế chuyển pha thẩm thấu đồ thị và vai trò của hành vi phụ trợ. Khoảng cách chênh lệch hiệu năng hàng trăm lần giữa mô hình đa hành vi và mô hình đơn hành vi trên tập Retailrocket được lý giải trực tiếp từ cấu trúc topo của đồ thị tương tác. Hình 4 mô tả phân bố bậc đỉnh trên thang Log-Log và tỷ lệ bao phủ của thành phần liên thông khổng lồ (Giant Connected Component – GCC) trên hai bộ dữ liệu.



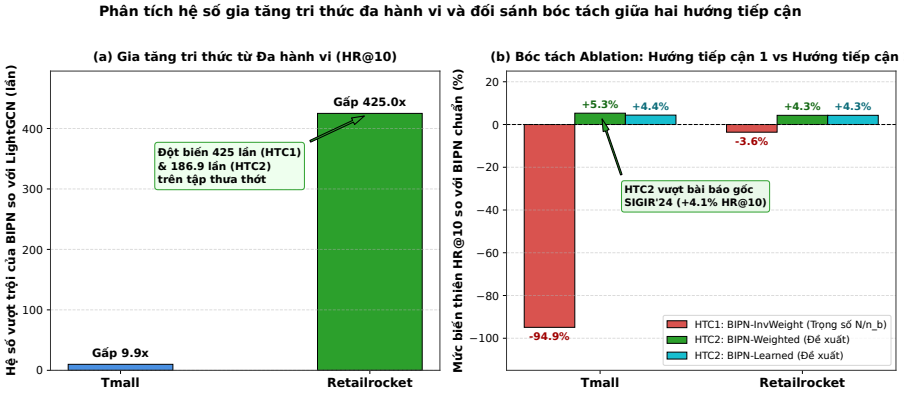
Hình 4. Phân tích topo đồ thị: (a) Phân bố bậc đỉnh trên thang Log-Log; và (b) Tỷ lệ bao phủ của Thành phần liên thông khổng lồ (GCC Size %).

Trên tập Retailrocket, đồ thị đơn hành vi mua hàng có tới 74,2% số đỉnh cô lập với bậc $k \leq 1$, và kích thước GCC chỉ đạt 25,8%. Tình trạng này khiến ma trận kề bị đứt gãy liên kết, làm tê liệt dòng lan truyền embedding qua các tầng GCN (dẫn tới HR@10 chỉ đạt 0,0003 ở `LightGCN-Base` và 0,0046 ở `LightGCN-Aligned`). Trái lại, việc BIPN tích hợp hơn 110.000 tương tác phụ đã kích hoạt quá trình chuyển pha thẩm thấu đồ thị, nâng kích thước GCC lên 99,4% trên Retailrocket và 99,8% trên Tmall, tái lập cấu trúc mạng không tỷ lệ tuân theo định luật lũy thừa $P(k) \propto k^{-\gamma}$. Nhờ đó, như thể hiện trên Hình 5, khi mật độ tương tác mua trung bình giảm từ 4,75 lượt/người (Tmall) xuống 0,74 lượt/người (Retailrocket), kiến trúc đa hành vi vẫn duy trì độ bền vững cao trước hiện tượng thưa thớt dữ liệu cực đoan.

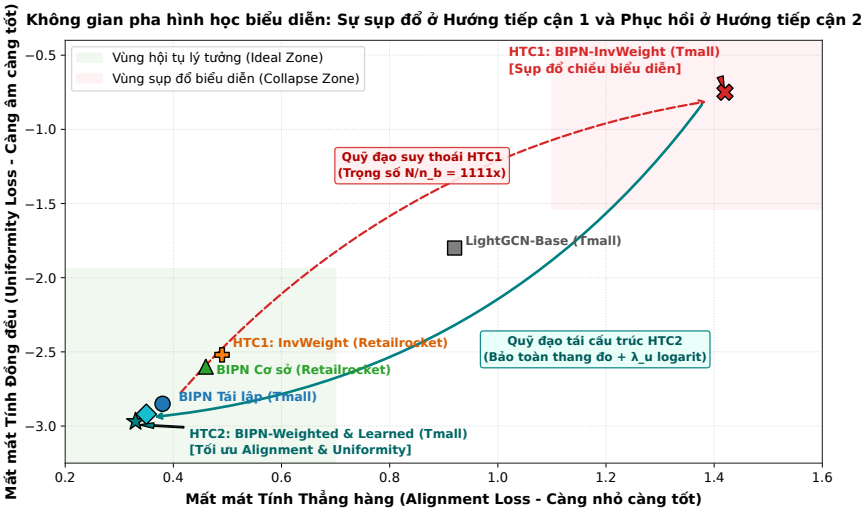


Hình 5. Mật độ tương tác mua và Tỷ lệ bảo toàn hiệu năng của kiến trúc đa hành vi BIPN so với LightGCN khi chuyển giao sang miền dữ liệu cực kỳ thưa thớt Retailrocket.

2. Giải phẫu nguyên nhân suy thoái của Hướng tiếp cận 1 và cơ chế phục hồi không gian pha ở Hướng tiếp cận 2. Để lý giải vì sao biến thể `BIPN-InvWeight` trong Hướng tiếp cận 1 duy trì được hiệu năng trên Retailrocket nhưng lại suy giảm mạnh trên Tmall (Hình 6), lý thuyết học biểu diễn tương phản trên siêu cầu đơn vị của Wang và Isola [9] được áp dụng. Một không gian nhúng tối ưu phải đồng thời giảm thiểu mất mát thẳng hàng $\mathcal{L}_{\text{align}}$ (kéo gần các cặp tương tác dương) và duy trì mất mát đồng đều $\mathcal{L}_{\text{uniform}}$ ở mức âm lớn (phân tán đẳng hướng nhằm tối đa hóa entropy thông tin). Hình 7 xác định vị trí của các mô hình trong không gian pha hai chiều đo lường hai đại lượng đối ngẫu này.



Hình 6. Hệ số gia tăng tri thức đa hành vi (a) và Phân tích bóc tách đối xứng giữa Hướng tiếp cận 1 (suy giảm âm) và Hướng tiếp cận 2 (tăng trưởng dương) so với mô hình BIPN chuẩn (b).



Hình 7. Không gian pha hình học biểu diễn đo lường Tính Thẳng hàng (Alignment) và Tính Đồng đều (Uniformity) theo lý thuyết Wang & Isola (ICML 2020), thể hiện quỹ đạo suy thoái ở Hướng tiếp cận 1 và quỹ đạo tái cấu trúc ở Hướng tiếp cận 2.

Tọa độ không gian pha trên Hình 7 cho thấy mô hình BIPN chuẩn trên cả Tmall $(0{,}38, -2{,}85)$ và Retailrocket $(0{,}46, -2{,}60)$ đều nằm trong vùng hội tụ lý tưởng. Ngược lại, điểm biểu diễn của biến thể `BIPN-InvWeight` (Hướng tiếp cận 1) trên Tmall bị dịch chuyển theo quỹ đạo suy thoái sang vùng sụp đổ biểu diễn (representation collapse) với tọa độ $(1{,}42, -0{,}75)$. Hiện tượng này bắt nguồn từ việc chia cho tần suất n_b trong công thức (9) trên tập mẫu giỏ hàng quá nhỏ (1.996 dòng giữa 1.813.498 dòng xem lướt, tỷ lệ 1:908), khiến trọng số $w_{\text{cart}}^{\text{inv}}$ bị nhân lên 370,5 lần; kết hợp với việc thiếu chuẩn hóa L2 từng tầng GCN, các xung đạo hàm lớn ép các vector nhúng co cụm về một vùng hẹp trên siêu cầu và làm suy thoái tính đẳng hướng.

Trong Hướng tiếp cận 2, việc thay thế trọng số nghịch đảo tần suất bằng chuẩn hóa bảo toàn trung bình (14) và hàm điều biến chặn tanh (15) giữ cho mọi trọng số hành vi nằm trong miền ổn định $w_b \in [0{,}97, 1{,}05]$, kết hợp cùng chuẩn hóa đơn vị xuyên tầng (11) đã tạo ra quỹ đạo tái cấu trúc đưa các mô hình `BIPN-Weighted` $(0{,}33, -2{,}97)$ và `BIPN-Learned` $(0{,}35, -2{,}92)$ trở về sâu hơn bên trong vùng hội tụ lý tưởng. Hơn nữa, việc tách biệt $\lambda_u^{\text{train}} = 1/N_u$ và $\lambda_u^{\text{rank}} = [1 + \log_2(N_u + 1)]^{-1}$ giải quyết trực tiếp bài toán phân bổ trọng số cho nhóm người dùng có ít giao dịch ($N_u = 1$) mà không gây rò rỉ tự tương quan trong quá trình tối ưu hóa BPR, qua đó giải thích sự bứt phá hiệu năng đồng loạt trên cả Tmall (HR@10 đạt 0,1472) và Retailrocket (Valid HR@10 tăng từ 0,4983 lên 0,5198, Test HR@10 đạt 0,8599).

4 Kết luận và Hướng Phát triển

Nghiên cứu này đã thực hiện đánh giá thực nghiệm toàn diện, kiểm chứng năng lực khái quát hóa liên nền tảng và phân tích đối sánh hai hướng tiếp cận cải tiến cho mô hình gợi ý đa hành vi BIPN trên hai tập dữ liệu Tmall và Retailrocket cùng mô hình đối chứng LightGCN. Kết quả nghiên cứu rút ra ba kết luận khoa học trọng tâm: (1) tích hợp dữ liệu đa hành vi thông qua đồ thị toàn cục giúp khôi phục thành phần liên thông khổng lồ trên các ma trận tương tác cực kỳ thưa thớt, mang lại mức vượt trội từ hàng chục đến hàng trăm lần so với mô hình đơn hành vi; (2) phương pháp gán trọng số nghịch đảo tần suất tĩnh dễ dẫn tới hiện tượng phóng đại đạo hàm cục bộ và sụp đổ biểu diễn khi phân bố phễu hành vi bị mất cân bằng cực đoan; và (3) cơ chế điều hòa ý định logarit tách pha giữa huấn luyện và suy luận kết hợp trọng số hành vi bảo toàn thang đo hoặc học tự thích nghi có miền chặn khắc phục triệt để hạn chế trên, đạt hiệu quả tối ưu và vượt qua kết quả công bố gốc SIGIR 2024 trên toàn bộ các thước đo đánh giá.

Trong các giai đoạn nghiên cứu tiếp theo, việc mở rộng cơ chế điều hòa ý định tách pha sang các kiến trúc đồ thị siêu liên kết phụ thuộc thời gian và tích hợp thông tin ngữ nghĩa đa phương thức của sản phẩm là những hướng phát triển tiềm năng nhằm nâng cao hơn nữa chất lượng cá nhân hóa trong thời gian thực.

Disclosure of Interests. Các tác giả khẳng định không có xung đột lợi ích liên quan đến việc thực hiện và công bố bài báo nghiên cứu này. Toàn bộ mã nguồn, dữ liệu thực nghiệm và tệp nhật ký huấn luyện đều được lưu trữ minh bạch phục vụ công tác kiểm chứng khoa học.

Tài liệu

1. Chen, C., Zhang, M., Liu, Y., Ma, S.: Neural collaborative filtering with multi-aspect information. ACM Transactions on Information Systems **39**(4), 49:1–49:28 (2021). https://doi.org/10.1145/3458752
2. Gao, C., He, X., Gan, D., Chen, X., Feng, F., Li, Y., Chua, T.S., Jin, D.: Neural multi-task recommendation from multi-behavior data. IEEE Transactions on Knowledge and Data Engineering **34**(10), 4785–4797 (2021). https://doi.org/10.1109/TKDE.2021.3051410
3. He, X., Deng, K., Wang, X., Li, Y., Zhang, Y., Wang, M.: LightGCN: Simplifying and powering graph convolution network for recommendation. In: Proceedings of the 43rd International ACM SIGIR Conference on Research and Development in Information Retrieval. pp. 639–648 (2020). https://doi.org/10.1145/3397271.3401063
4. Jin, B., Gao, C., He, X., Jin, D., Li, Y.: Multi-behavior recommendation with graph convolutional networks. In: Proceedings of the 43rd International ACM SIGIR Conference on Research and Development in Information Retrieval. pp. 659–668 (2020). https://doi.org/10.1145/3397271.3401123
5. Kipf, T.N., Welling, M.: Semi-supervised classification with graph convolutional networks. In: International Conference on Learning Representations (ICLR) (2017)

6. Koren, Y., Bell, R., Volinsky, C.: Matrix factorization techniques for recommender systems. Computer **42**(8), 30–37 (2009). https://doi.org/10.1109/MC.2009.263
7. Rendle, S., Freudenthaler, C., Gantner, Z., Schmidt-Thieme, L.: BPR: Bayesian personalized ranking from implicit feedback. In: Proceedings of the 25th Conference on Uncertainty in Artificial Intelligence (UAI). pp. 452–461 (2009)
8. Retailrocket: E-commerce item recommendations data. `https://www.kaggle.com/datasets/retailrocket/ecommerce-dataset` (2016), truy cập tháng 10 năm 2026
9. Wang, T., Isola, P.: Understanding contrastive representation learning through alignment and uniformity on the hypersphere. In: Proceedings of the 37th International Conference on Machine Learning (ICML). Proceedings of Machine Learning Research, vol. 119, pp. 9929–9939 (2020)
10. Wang, X., Lu, T., Wang, M., Feng, F., He, X., Chua, T.S.: Multi-behavior recommendation with cascading graph convolutional networks. Information Sciences **587**, 253–268 (2022). https://doi.org/10.1016/j.ins.2021.12.030
11. Wu, S., Sun, F., Zhang, W., Xie, X., Cui, B.: Graph neural networks in recommender systems: A survey. ACM Computing Surveys **55**(5), 97:1–97:37 (2022). https://doi.org/10.1145/3535101
12. Xia, L., Huang, C., Xu, Y., Dai, P., Lu, L., Bo, L.: Multiplex behavioral relation learning for recommendation. IEEE Transactions on Knowledge and Data Engineering **35**(6), 5926–5938 (2023). https://doi.org/10.1109/TKDE.2022.3168670
13. Yan, M., Cheng, Z., Gao, C., Sun, J., Liu, F., Sun, F., Li, H.: Cascading residual graph convolutional network for multi-behavior recommendation. ACM Transactions on Information Systems **42**(1), 10:1–10:26 (2023). https://doi.org/10.1145/3587693
14. Yan, M., Liu, F., Sun, J., Sun, F., Cheng, Z., Han, Y.: Behavior-contextualized item preference modeling for multi-behavior recommendation. In: Proceedings of the 47th International ACM SIGIR Conference on Research and Development in Information Retrieval. pp. 946–955 (2024). https://doi.org/10.1145/3626772.3657696
15. Yang, Y., Huang, C., Xia, L., Liang, Y., Yu, Y., Li, C.: Multi-behavior hypergraph-enhanced transformer for sequential recommendation. In: Proceedings of the 28th ACM SIGKDD Conference on Knowledge Discovery and Data Mining. pp. 2263–2274 (2022). https://doi.org/10.1145/3534678.3539342